



دانشگاه صنعتی شریف
دانشکده مهندسی کامپیوتر

پایان نامه کارشناسی ارشد
گرایش هوش مصنوعی

بهبود یادگیری در مدل های مبتنی بر نوسانگرهای فاز

نگارش
میثم عقیقی

استاد راهنما
دکتر مهدی جلیلی

پاییز ۱۳۹۱

دانشگاه صنعتی شریف
دانشکده کامپیوتر

رساله کارشناسی ارشد

بهبود یادگیری در مدل‌های مبتنی بر نوسانگرهای فاز

نگارش: میثم عقیقی

امضاء:

استاد راهنما: دکتر مهدی جلیلی

امضاء:

استاد ممتحن داخلی: دکتر حمیدرضا ربیعی

امضاء:

استاد ممتحن خارجی: دکتر محمدباقر شمس‌الهی

قدردانی

خدای بزرگ را شاکرم که مرا آفرید و هرچه دارم از اوست.
بر خود لازم می‌دانم از دکتر مهدی جلیلی که در آزمایشگاه پژوهشی‌شان فضای مناسبی را برای فعالیت علمی فراهم کرده‌اند و علی‌رغم سفر به خارج از کشور حمایت‌ها و پی‌گیری‌هایشان را از من دریغ نداشتند تشکر و قدردانی کنم.

هم‌چنین از دوستانم در آزمایشگاه پژوهشی پردازش داده‌های شبکه‌ای تشکر می‌کنم.
در این میان از آقای جودکی به خاطر کمک‌های علمی فراوان ایشان، و به خصوص از آقایان پدرود و محمدی‌نژاد به دلیل حمایت‌های علمی و فراعلمی خود که بدون این حمایت‌ها طی این مسیر برای من میسر نبود، تشکر و قدردانی می‌کنم.

تقدیم

این پایان نامه را به خانواده عزیزم و همسر مهربانم که هر آن چه دارم از آن هاست، تقدیم می کنم؛

چکیده

در سال‌های اخیر و همراه با توسعه علوم شناختی، مسأله یادگیری نوسانگرهای فاز مورد توجه فراوانی قرار گرفته است. در این دیدگاه نوروها دیگر ساختار جداگانه و مستقلی ندارد و یک واحد محاسباتی تنها نیستند، بلکه در یک گروه منسجم از نوسانگرها قرار گرفته‌اند. به طور تجربی نشان داده شده است که همزمانی این نوسانگرها با اعمال ادراکی مغز رابطه نزدیکی دارد، از این رو ارائه یک مدل یادگیری برای شبکه نوسانگرهای فاز اهمیت فراوانی دارد. در این پژوهش ما یک مدل جدید محرک-پاسخ با هدف یادگیری و شناسایی ارائه کردیم. بخش مهم کار ما تعریف کردن روشی برای یادگیری فرکانس طبیعی نوسانگرها و ضریب اتصالات میان آن‌ها، در یک شبکه نوسانگرهای فاز تحت شرایط کوراموتو می‌باشد.

در این پژوهش، ما نه تنها با اهمیت دادن به فرکانس نوسانگرها، بلکه با پرداختن به ضرایب سیناپسی، به بهبود مدل‌های پیشین پرداخته‌ایم. ما یک الگوریتم یادگیری برای مدل ارائه شده، ارائه کردیم و آن را بر روی برخی مسائل دسته‌بندی شامل مجموعه داده‌های Iris و Cars اجرا کردیم. نتایج این پیاده‌سازی‌ها برتری مدل ارائه شده را بر مدل‌های پیشین با معیار نرخ شناسایی نشان می‌دهد. همچنین، مدل ارائه شده نرخ شناسایی بهتری را در مواجهه با نویز، با مقایسه با مدل‌های پیشین از خود نشان داد.

کلمات کلیدی: نوسانگر فاز، شبکه نوسانگرهای عصبی، مدل کوراموتو، شناسایی الگو

فهرست مطالب

۱	مقدمه	۱
۲	۱.۱ شرح مسأله	۲
۳	۲.۱ کاربرد مسأله و سابقه‌های تحقیقات	۳
۴	۳.۱ اهداف پژوهش	۴
۴	۴.۱ خلاصه فرایند پژوهش	۴
۵	۱.۴.۱ رویکرد شناسایی الگو	۵
۵	۵.۱ نوآوری‌ها و نتایج پژوهش	۵
۶	۶.۱ معرفی ساختار پایان‌نامه	۶
۷	۲ همزمانی و نوسانگرهای فاز	۷
۸	۱.۲ مدل‌های ارائه شده برای شبکه‌ی نوسانگرهای فاز	۸
۸	۱.۱.۲ مدل کوراموتو	۸
۱۰	۲.۱.۲ مدل‌های همراه با پالس	۱۰
۱۱	۳.۱.۲ نقشه‌های متصل به هم	۱۱
۱۳	۲.۲ تعاریف موجود برای همزمانی در شبکه‌های پیچیده	۱۳
۱۳	۱.۲.۲ معیارهای سراسری	۱۳
۱۵	۲.۲.۲ معیارهای محلی	۱۵
۱۶	۳.۲ روش‌های بهبود همزمانی	۱۶

۱۸	۳ مدل‌های پیشین
۱۸	۱.۳ مدل‌های یادگیری مبتنی بر شناسایی اتصالات سیناپسی
۱۹	۱.۱.۳ مدل‌های مبتنی بر شبکه‌های عصبی چند لایه [۱، ۲]
۲۱	۲.۱.۳ یادگیری اتصالات در شبکه نوسانگرهای فاز [۳]
۲۳	۳.۱.۳ بهره‌گیری از قانون یادگیری هب در شبکه نوسانگرهای فاز [۴]
۲۴	۲.۳ مدل‌های یادگیری مبتنی بر شناسایی خصوصیات محلی نوسانگرها
۲۴	۱.۲.۳ مدل مبتنی بر شبه-همزمانی نوسانگرهای فاز [۵]
۲۶	۳.۳ مدل‌های یادگیری ترکیبی
۲۶	۱.۳.۳ پردازش خصوصیات محلی و سراسری در شبکه نوسانگرهای عصبی [۶]
	۲.۳.۳ شبکه نوسانگرهای فاز به عنوان یک مدل عصبی برای شایسته‌سازی محرک-
۲۸	پاسخ [۷]
۳۲	۴.۳ مقایسه و جمع‌بندی
۳۳	۴ مدل بهبودیافته و نتایج پیاده‌سازی
۳۳	۱.۴ مشکلات موجود در روش‌های پیشین
۳۵	۲.۴ مدل ارائه شده
۳۸	۳.۴ شناسایی الگو
۴۱	۱.۳.۴ مقاومت نسبت به نویز
۴۲	۲.۳.۴ شناسایی تصویر نویزی
۴۷	۳.۳.۴ سایر مسائل شناسایی الگو
۵۱	۵ جمع‌بندی و پیشنهادهایی برای پژوهش‌های آینده
۵۶	۶ مراجع

فهرست اشکال

- ۱.۱ نمودار بلوکی یک سیستم عصبی ۲
- ۱.۳ نمونه‌ای از یک پرسپترون چندلایه، تشکیل شده از لایه ورودی، لایه میانی (پنهان) و لایه خروجی ۲۰
- ۲.۳ دو نوسانگر نشان دهنده جمعیت نورون‌های هدایت شده (nXIIts و Ram) توسط نوسانگر استاد (HVC) اعمال استاد را با تأخیرهای متفاوت تکرار می‌کنند. این دو جمعیت از نورون‌ها بخش‌های مختلف تولید آوا هستند: هسته موسیقار (syringeal nucleus) و ماهیچه تنفسی (respiratory muscle) [۳] ۲۲
- ۱.۴ نحوه اتصال نوسانگرهای فاز در مدل ارائه شده، همان طور که در شکل دیده می‌شود نوسانگرها به دو دسته محرک و پاسخ تقسیم می‌شوند. اتصالات میان نوسانگرهای محرک و پاسخ و اتصالات میان نوسانگرهای پاسخ موجود هستند، ولی میان نوسانگرهای محرک اتصالی وجود ندارد. ۳۷
- ۲.۴ نمودار درصد شناسایی صحیح الگوهای پاسخ برای مجموعه محرک نویزی، بر حسب تغییرات تعداد نوسانگرهای پاسخ. این نمودار برای تعداد نوسانگرهای محرک مختلف (۵، ۱۰ و ۲۰) رسم شده است. ۴۳
- ۳.۴ ارقام ۰، ۱ و ۲ با تعداد 107×80 پیکسل که هر رقم توسط یک دنباله به طول ۸۵۶۰ قابل نمایش است. ۴۴

۴.۴	مقایسه درصد شناسایی صحیح رقم‌های نویزی بر حسب نسبت سیگنال به نویز تصویر در سه مدل مختلف، ۱- شبکه نوسانگرهای عصبی متشکل از ۳۰ نوسانگر فاز که با الگوریتم‌های یادگیری ارائه شده آموزش دیده‌اند. ۲- شبکه نوسانگرهای عصبی ارائه شده در [۵] و ۳- یک شبکه عصبی متشکل از ۲۰ نورون لایه پنهان	۴۵
۵.۴	تصاویر نویزی رقم صفر	۴۶
۶.۴	مقایسه نتایج شناسایی مجموعه داده Iris به دست آمده از مدل ارائه و [۵]، بر حسب تعداد نوسانگرهای پاسخ	۴۸
۷.۴	مقایسه نتایج شناسایی مجموعه داده Cars به دست آمده از مدل ارائه و [۵]، بر حسب تعداد نوسانگرهای پاسخ	۵۰
۱.۵	منبع ایجاد میدان مغناطیسی در مغز، این جریان مغناطیسی (electric current) است که باعث ایجاد سیگنال‌های EEG و MEG می‌شود. تصویر فوق از کمپانی MedTech که تولید کننده CTF MEG می‌باشد، گرفته شده است.	۵۲
۲.۵	نمونه‌ای از یک سیگنال EEG، سیگنال‌هایی که در شکل فوق مشاهده می‌شود تغییرات ولتاژ بر حسب زمان در طول ۱ ثانیه برای ۵ الکتروود از یک داده EEG گرفته شده از یک بیمار می‌باشد.	۵۳
۳.۵	نمونه‌ای از یک داده fMRI اسکن شده، گرفته شده از National Institute of Mental Health.	۵۴

فهرست جداول

۱.۳	مقایسه و جمع‌بندی کارهای پیشین	۳۲
۱.۴	لیست متغیرهای موجود در مدل پیشنهادی	۳۶
۲.۴	مشخصات آماری خصوصیت‌های مجموعه داده Iris	۴۷
۳.۴	نام و مقادیر خصوصیت‌های مجموعه داده Cars	۴۹

فصل ۱

مقدمه

کار بر روی شبکه‌های عصبی مصنوعی^۱ از زمانی که بشر دریافت مغز انسان به روشی متفاوت از کامپیوتر کار می‌کند، شروع شد و هم‌چنان ادامه دارد. مغز انسان دارای ساختاری پیچیده و غیرخطی است و توانایی پردازش موازی دارد. هم‌چنین قادر به سازماندهی اجزای اصلی تشکیل دهنده‌اش به نام نورون است، تا بتواند یک هدف خاص را (مانند شناسایی الگو، ادراک^۲ و کنترل ماشین) بسیار سریع تر از قوی‌ترین کامپیوترهای امروزی انجام دهد.


با ظهور تجربه‌های مدرن و روش‌های محاسباتی جدید، تلاش‌هایی اساسی برای شناختن روش یادگیری مغز انجام شده است. برای مثال، شبیه‌سازی رفتار شبکه‌ای از نورون‌ها با شروع از جریان یون‌هایی که در غشاء نورون‌ها هستند، توسط مدل‌های محاسباتی برپایه اطلاعات تجربی امکان‌پذیر شده است [۸]. با این وجود هنوز حجم وسیعی از اتفاقات کشف نشده در سطح سیستمی از روندهای مغز وجود دارد که این در مقابل حجم زیاد مطالعات در زمینه روانشناسی یادگیری^۳ و ادراک، بسیار ناچیز است. در این میان از بین همه مدل‌های یادگیری مطرح شده، مدل محرک-پاسخ^۴ یکی از رایج‌ترین مدل‌ها است [۹، ۱۰، ۱۱].

^۱artificial neural network

^۲perception

^۳psychology on learning

^۴stimulus-response



شکل ۱۰۱: نمودار بلوکی یک سیستم عصبی

۱.۱ شرح مسأله

یکی از مسائل مطرح در این زمینه ارائه یک مدل یادگیری مناسب و برگرفته از داده های بیولوژیکی است. سیستم عصبی مغز انسان همانند شکل ۱۰۱ در یک ساختار ۳ مرحله‌ای قابل بیان است. در مرکز این سیستم مغز قرار دارد که با یک شبکه عصبی نمایش داده شده است. این بخش به طور دائم در حال دریافت اطلاعات، درک آن و اخذ تصمیم‌های مطلوب است. فلش‌های رو به جلو نمایانگر انتقال سیگنال‌های حاوی اطلاعات، و فلش‌های رو به عقب نمایانگر بازخورد^۵ در سیستم هستند. بخش گیرنده محرک، با گرفتن محرک از محیط (بدن انسان) آن را به ضربه‌های الکتریکی^۶ تبدیل کرده و اطلاعات را با این روش به مغز انتقال می‌دهد. بخش پاسخ دهنده نیز با دریافت ضربه‌های الکتریکی از مغز آن را به پاسخ‌های قابل فهم در خروجی سیستم تبدیل می‌کند.

اجزای اصلی تشکیل دهنده مغز عبارت‌اند از نورون و سیناپس. نورون‌های در حدود ۵ تا ۶ برابر کندتر از گیت‌های منطقی هستند. با این وجود مغز دارای تعداد بسیار زیادی نورون با اتصالات بسیار پیچیده میان آن‌هاست. تخمین زده شده که مغز انسان در حدود ۱۰ میلیارد نورون و در حدود ۶۰ هزار میلیارد سیناپس دارد [۱۱].

با توجه به مطالب گفته شده یکی از اهدافی که محققین در این زمینه از حدود ۳۰ سال پیش تاکنون همواره به آن پرداخته‌اند، ارائه مدلی است متشکل از نورون‌ها و سیناپس‌ها، و بیان یک روش یادگیری برای آن به طوری که تعدادی از نورون‌ها به نام نورون‌های محرک به عنوان ورودی و تعداد دیگری به نام

^۵feedback

^۶electrical impulse

نورون‌های پاسخ به عنوان خروجی در نظر گرفته شوند.

۲.۱ کاربرد مسأله و سابقه‌های تحقیقات

اصلی‌ترین دسته از کارهایی که در این زمینه انجام شده است، در شاخه شبکه‌های عصبی مصنوعی است. اول این که یک شبکه عصبی دارای این خاصیت است که بدون داشتن اطلاعات صریحی از مشخصات تابعی و یا نوع توزیع یک سیستم، قادر به تطبیق خود با آن است. دوم این که شبکه عصبی دارای این خاصیت است که تقریب‌زننده عمومی^۷ است و به صورت تئوری قادر به تخمین همه توابع پیوسته بر روی \mathbb{R}^n می‌باشد [۱۲، ۱۳، ۱۴]. و سوم این که شبکه‌های عصبی مدل‌هایی غیرخطی می‌باشند، و این باعث سازگاری بیشتر آن‌ها با مدل‌سازی مسائل پیچیده جهان واقعی است.

از طرف دیگر، موثر بودن شبکه‌های عصبی در حل مسائل دسته‌بندی^۸ در مثال‌های تجربی فراوانی به اثبات رسیده است. شبکه‌های عصبی به طور موفق در بسیاری از مسائل جهان واقعی به کار برده شده است. از این دسته می‌توان به کاربرد آن در صنعت، تجارت و سایر علوم [۱۵]، پیش‌بینی ورشکستگی [۱۶، ۱۷، ۱۸، ۱۹، ۲۰، ۲۱]، تشخیص دست خط [۲۲، ۲۳، ۲۴، ۲۵، ۲۶]، بازشناسایی گفتار [۲۷، ۲۸]، تشخیص خطا [۲۹] و تشخیص بیماری [۳۰، ۳۱، ۳۲، ۳۳] اشاره کرد. همان طور که دیده می‌شود همه این کاربردها با هدف شناسایی الگو و یا دسته‌بندی انجام شده‌اند، و مقایسه‌های فراوانی بین دسته‌بندی‌های متفاوت و دسته‌بندی‌های بر پایه شبکه‌های عصبی انجام شده است [۲، ۳۴، ۳۵، ۳۶]. یکی دیگر از رویکردهای اخیر برای این مسأله، در نظر گرفتن نوسانگرهای عصبی^۹ متشکل از تعدادی نورون همزمان شده^{۱۰} در مغز می‌باشد. این حقیقت نوروفیزیولوژیکی^{۱۱} برگرفته از مشاهدات درشت نمود^{۱۲} توسط دستگاه ثبت امواج الکتریکی مغز^{۱۳} است [۳۷، ۳۸، ۳۹]. تحقیقات تئوری دقیقی نشان داده است که نورون‌های در آستانه شکاف^{۱۴} رفتاری شبیه یک نوسانگر از خود نشان

^۷universal approximator

^۸classification

^۹neural oscillators

^{۱۰}synchronized

^{۱۱}neurophysiological

^{۱۲}macroscopic

^{۱۳}electroencephalogram

^{۱۴}bifurcation

می‌دهند [۳۸، ۴۰، ۴۱]. علاوه بر این بسیاری از تحقیقات نه تنها خبر از وجود نوسانگرها در مغز می‌دهند [۴۲، ۴۳، ۴۴، ۴۵]، که نشان دهنده‌ی ارتباط همزمانی آن‌ها با اعمال ادراکی^{۱۵} مغز نیز هستند [۴۳، ۴۴، ۴۶، ۴۷، ۴۸].

تاکنون نوسانگرهای عصبی برای مدل کردن طیف وسیعی از اعمال مغز به کار رفته‌اند. از این قبیل می‌توان به سلول‌های هرمی [۴۸]، تأثیر میدان الکتریکی بر روی بیماری صرع [۴۹]، فعالیت‌های درون غشاء بصری گربه [۶]، یادگیری موسیقی توسط پردندگان [۳] و یادگیری شناسایی الگو [۵] اشاره کرد.

۳.۱ اهداف پژوهش

از جمله اهدافی که می‌توان برای انجام این کار پژوهشی بر شمرده عبارتند از:

- آشنایی با برخی مفاهیم شبکه‌های عصبی، شبکه‌های پیچیده و شبکه‌های نوسانگرهای فاز
- مطالعه روش‌های مطرح شده برگرفته از شبکه‌های عصبی برای یادگیری مدل محرک-پاسخ
- مطالعه روش‌های مطرح شده برگرفته از همزمانی در شبکه‌های نوسانگرهای فاز برای یادگیری مدل محرک-پاسخ
- بررسی، مقایسه و نقد روش‌های پیشین با رویکرد شناسایی الگو
- پیشنهاد یک روش بهبود یافته برای یادگیری و مقایسه آن با روش‌های پیشین

۴.۱ خلاصه فرایند پژوهش

بعد از مطالعه مدل‌های پیشین مطرح شده برای مسأله و بررسی خواستگاه آن‌ها، این مطلب دیده می‌شود که مدل نوسانگرهای فاز به کاربردهای عملی نزدیک‌تر است و همان طور که گفته شد مهم‌ترین دلیل این امر ارتباط مستقیم آن با داده‌های دستگاه ثبت امواج مغز (EEG)^{۱۶} است. از سوی دیگر در اکثر این مدل‌ها برای سادگی معادلات و در برخی موارد برای سادگی محاسبات، اتصالات میان نوسانگرهای شبکه به طور یکنواخت در نظر گرفته شده است. و در واقع در مواردی که یادگیری توسط این شبکه

^{۱۵}perceptual processing

^{۱۶}electroencephalography

صورت گرفته است، دانش^{۱۷} یادگرفته شده فقط در فرکانس (معمولاً فرکانس طبیعی) نوسانگرها ذخیره شده است. در صورتی که این فرض به وضوح فرض درستی نیست، زیرا که در بخش قبل گفته شد که آزمایش‌های عملی نشان داده‌اند که دانش در شبکه‌های عصبی در اتصالات سیناپسی بین نورونی ذخیره شده است.

از این رو بر آن شدیم که با ترکیب مدل‌های یادگیری برپایه یادگیری فرکانس طبیعی شبکه نوسانگرهای فاز، و همچنین مدل‌های برپایه یادگیری وزن‌های سیناپسی بین نورون‌ها به مدل جدیدی برای یادگیری برسیم.

۱.۴.۱ رویکرد شناسایی الگو

بعد از ارائه مدل، علاوه بر بررسی خاصیت‌های شبکه‌ای آن و مقایسه با مدل‌های پیشین، نیاز به معیاری برای بررسی توانایی یادگیری مدل جدید و مقایسه با مدل‌های پیشین داریم. از این رو با توجه به ذات مسئله و مدل محرک-پاسخ، بهترین معیار، توانایی حل مسائل شناسایی الگو می‌باشد که در فصل ۴ به آن می‌پردازیم.

۵.۱ نوآوری‌ها و نتایج پژوهش

در این پژوهش بعد از مطالعه روش‌های و مدل‌های پیشین مطرح شده برای ارائه یک سیستم یادگیرنده برپایه شبکه‌ای از نوسانگرهای عصبی، یک مدل یادگیری در همین زمینه ارائه شد. در این مدل یادگیری که متشکل از یک شبکه از نوسانگرهای فاز با معادلات کوراموتو می‌باشد، نوسانگرها به دو دسته محرک و پاسخ تقسیم می‌شوند. ما در این مقاله الگوریتم جدیدی برای یادگیری پارامترهای شبکه ارائه کرده‌ایم. نوآوری این الگوریتم در ارائه قوانین یادگیری همزمان هم برای اتصالات سیناپسی موجود در شبکه و هم برای فرکانس طبیعی نوسانگرهای آن می‌باشد. این قوانین یادگیری در فصل ۴ به طور کامل توضیح داده شده‌اند.

پس از ارائه این مدل یادگیری جدید به بررسی خواص آن پرداختیم. یکی از مهم‌ترین این خاصیت‌ها مقاومت این مدل نسبت به نویز می‌باشد که در نتیجه باعث می‌شود که بتوان از آن در مسائل بیوانفورماتیک که در آن‌ها با نویز فراوانی سروکار داریم، استفاده کنیم. پس از این قابلیت شناسایی الگو این مدل مورد

^{۱۷}knowledge

بحث قرار گرفته است. برای این مهم به حل دو مسأله شناسایی الگو پرداختیم که نتایج شبیه‌سازی‌ها در بخش ۳.۴ آمده است. در این بخش می‌بینیم که مدل مذکور توانسته الگوهای مورد نظر را به خوبی شناسایی کند.

۶.۱ معرفی ساختار پایان‌نامه

در این فصل به معرفی ساختار مسأله پرداختیم. در فصل ۲ به بررسی نوسانگرهای فاز، مدل کوراموتو و سایر مدل‌های مطرح برای توجیه همزمانی در شبکه‌های پیچیده می‌پردازیم. همچنین تعاریف موجود برای همزمانی و روش‌های مطرح شده برای بهبود همزمانی در شبکه‌ها در آن فصل مرور خواهند شد. در فصل ۳ به بیان مدل‌های یادگیری پیشین می‌پردازیم. در این بخش مدل‌ها به سه دسته کلی بر حسب نوع یادگیری آن‌ها و این که دانش در چه بخشی از شبکه اعم از وزن اتصالات سیناپسی و یا مشخصات محلی نوسانگرها ذخیره می‌شود، تقسیم شده‌اند. در فصل ۴، پس از بیان نقاط ضعف مشاهده شده در مدل‌های پیشین به بیان روش‌هایی برای بهبود این مدل‌ها و بررسی آن‌ها می‌پردازیم. همچنین قوانین یادگیری جدید به دست آمده را بیان کرده و در آخر نتایج پیاده‌سازی مدل جدید و مدل‌های پیشین برای بر روی چند مسأله شناسایی الگو آورده شده است. در فصل ۵ به جمع‌بندی مدل ارائه شده و نتایج آن، همچنین مسیریابی برای کارهای آتی در این بخش پرداخته‌ایم.

فصل ۲

همزمانی و نوسانگرهای فاز

پدیده همزمانی اجزای تشکیل دهنده یک اجتماع، از گذشته دور مورد توجه بشر قرار داشته و همواره در تلاش برای توجیه آن بوده است. این پدیده همواره در طبیعت حاضر بوده، و در بسیاری از علوم مانند زیست‌شناسی^۱، بوم‌شناسی^۲، اقلیم‌شناسی^۳، جامعه‌شناسی^۴ و حتی هنر^۵، نقش مهمی را ایفا می‌کند. این پدیده با زندگی انسان هم رابطه نزدیکی دارد، از روندهای سوخت و سازی^۶ درون سلول‌های بدن گرفته تا رفتار گروهی از افراد مستقل از هم در یک اجتماع. مانند عملکرد سلول‌های دستگاه تنظیم کننده ضربان قلب، واکنش گروهی از کودکان به موسیقی و یا رفتار نوازندگان در یک کنسرت و به طور مقابل تشویق تماشاچیان.

از میان همه تلاش‌های انجام شده در این زمینه یکی از مهم‌ترین آن‌ها در سال ۱۶۶۵ توسط ریاضیدان و فیزیکدان هاجینز^۷ انجام شد. او پس از مشاهده همزمانی فرکانس نوسان آونگ دو ساعت آونگ‌دار که در کنار یکدیگر قرار دارند، بیان کرد که این اتفاق تحت تأثیر حرکاتی غیرقابل مشاهده^۸ و از طریق

^۱biology

^۲ecology

^۳climatology

^۴sociology

^۵arts

^۶metabolic

^۷C.Huygens

^۸imperceptible movements

قاب مشترک میان دو آونگ می‌باشد. از آن به بعد بررسی رفتار چند نوسانگر متصل به یکدیگر توسط محققین آغاز شد.

این تلاش‌ها برای توجیه همزمانی پدیده‌های طبیعی ادامه داشت تا این که وینفری^۹ به بررسی رفتار یک شبکه از نوسانگرها با اتصالات ضعیف پرداخت که فرکانس طبیعی همه آن‌ها از یک توزیع مشخص آمده است. در این جا او این نوسانگرها را نوسانگرها فاز^{۱۰} در نظر گرفت و از دامنه^{۱۱} صرف‌نظر کرد. او مشاهده کرد که چنین جامعه‌ای از نوسانگرها مستقل از همدیگر حول فرکانس طبیعی خود نوسان می‌کنند. با کم کردن واریانس فرکانس‌های طبیعی آن‌ها، این رفتار تا یک آستانه خاص ادامه خواهد داشت. بعد از رد شدن از این آستانه نوسانگرها شروع به همزمانی به صورت خودبخودی کردند [۵۰]. مشکل اصلی این مدل فرض اتصال همه نوسانگرها به یکدیگر بود که این فرض در شبکه‌های واقعی برقرار نیست. بعد از آن نیز کارهای مختلفی برای این منظور انجام شده است که در بخش‌های آتی به دسته‌بندی و بیان آن‌ها می‌پردازیم.

۱.۲ مدل‌های ارائه شده برای شبکه‌ی نوسانگرهای فاز

پس از مطالعه و دسته‌بندی رویکردهای مختلف برای مدل کردن پدیده همزمانی توسط نوسانگرها در شبکه‌های پیچیده، در این بخش به بررسی سه روش اصلی در این زمینه می‌پردازیم: مدل کوراموتو^{۱۲}، مدل‌های همراه با پالس^{۱۳} و نقشه‌های به هم متصل^{۱۴}.

۱.۱.۲ مدل کوراموتو

پس از مدل مطرح شده توسط [۵۰] Winfree، ریاضیدانان برای مدل کردن پدیده همزمانی توسط نوسانگرها به این مسأله روی آوردند. یکی از رویکردهای موجود، شبکه‌ای از نوسانگرها با اتصالات ضعیف بود، که در آن همه نوسانگرها تقریباً در شرایط یکسانی به سر می‌بردند و تأثیر اندکی بر روی فاز

^۹Winfree

^{۱۰}phase oscillator

^{۱۱}amplitude

^{۱۲}kuramoto

^{۱۳}pulse-coupled

^{۱۴}coupled maps

نوسانگرهای مجاور خود می‌گذاشتند که این تأثیر در یک معادله حساسیت ذکر شده بود [۵۱].

با وجود این که مدل فوق خیلی ساده به نظر می‌رسد ولی پدیده‌های مورد نظر را توجیه می‌کند. به این صورت که تا وقتی اختلاف فرکانس نوسانگرها به نسبت ضریب اتصالات میان آن‌ها مقدار زیادی باشد، آن‌ها مستقل از همدیگر حول فرکانس طبیعی خود نوسان می‌کنند. و هنگامی که ضریب اتصالات میان آن‌ها زیاد شود تا به یک آستانه برسد، نوسانگرها شروع به همزمان شدن می‌کنند و به اصطلاح فاز آن‌ها قفل می‌شود^{۱۵}. در این شرایط نوسانگرها به چند خوشه تبدیل می‌شوند که در هر خوشه نوسانگرها با یکدیگر همزمان هستند. در ادامه با افزایش ضریب اتصالات همه نوسانگرها شروع به همزمانی با یکدیگر می‌کنند و در نهایت سیستم به یک حالت همزمانی کامل می‌رسد.

کوراموتو [۵۱] به بررسی یک مدل ریاضی پرداخت که قابلیت توجیه پدیده فوق را داشته باشد. مدلی که او مطرح کرد یک شبکه از نوسانگرهای دو به دو متصل بود که در آن دو نوسانگر متصل به هم، تأثیری سینوسی از اختلاف فازشان بر روی یکدیگر می‌گذاشتند. او برای هر نوسانگر رابطه زیر را مطرح کرد:

$$\dot{\theta}_i = \omega_i + \frac{K}{N} \sum_{j=1}^N \sin(\theta_j - \theta_i) \quad (i = 1, \dots, N), \quad (1.2)$$

که در رابطه فوق θ_i برابر فاز نوسانگر i -ام می‌باشد. همچنین ضریب $1/N$ برای تصحیح رفتار سیستم هنگامی که $N \rightarrow \infty$ می‌باشد. ω_i نمایانگر فرکانس طبیعی نوسانگر i -ام، و K ضریب اتصال است. فرکانس‌های ω_i از یک توزیع $g(\omega)$ می‌آیند که معمولاً دارای یک مد^{۱۶}، و حول میانگین (Ω) متقارن است. که با خاصیت اخیر می‌توان با انجام تبدیل $\omega_i \rightarrow \omega_i + \Omega$ برای هر i ، $\Omega = 0$ را قرار داد، که در این صورت فرکانس ω_i نمایانگر انحراف حول فرکانس میانگین خواهد بود.

در این مدل دینامیک قابل استخراج از کل شبکه، که به آن پارامتر نظم^{۱۷} گفته می‌شود، برابر است

با

$$r(t)e^{i\phi(t)} = \frac{1}{N} \sum_{j=1}^N e^{i\theta_j(t)}, \quad (2.2)$$

که در آن $0 \leq r(t) \leq 1$ نشان دهنده ارتباط میان فازهای نوسانگرهای شبکه و $\phi(t)$ فاز میانگین است. مقادیر $1 \simeq r$ و $0 \simeq r$ (که در آن \simeq نشان دهنده نوسانات از اندازه $O(N^{-1/2})$ است) به ترتیب توصیف کننده حالت‌هایی هستند که در آن همه نوسانگرها فاز قفل شده دارند و یا کاملاً مستقل از هم

^{۱۵}phase-locked

^{۱۶}unimodal

^{۱۷}order parameter

تغییر می‌کنند. با ضرب طرفین رابطه ۲.۲ در $e^{-i\theta_i}$ و برابر قرار دادن بخش موهومی دو طرف به دست می‌آوریم:

$$r \sin(\phi - \theta_i) = \frac{1}{N} \sum_{j=1}^N \sin(\theta_j - \theta_i), \quad (3.2)$$

و در نتیجه

$$\dot{\theta}_i = \omega_i + K r \sin(\phi - \theta_i) \quad (i = 1, \dots, N). \quad (4.2)$$

رابطه ۴.۲ بیان می‌کند که هر نوسانگر فقط از طریق مقادیر r و ϕ با سایر نوسانگرها در ارتباط است. در واقع با زیاد شدن r نوسانگرها بیشتر به یکدیگر وابسته بوده و اتصال میان آن‌ها قوی‌تر خواهد بود. علاوه بر این، رابطه ۴.۲ کمک می‌کند که یک ضریب اتصال بحرانی K_c ^{۱۸} برای شبکه به دست آید:

$$K_c = \frac{2}{\pi g(\cdot)} \quad (5.2)$$

ثابت شده است که اگر ضریب اتصال از K_c بیشتر باشد، شبکه همواره به حالت همزمانی کامل میان نوسانگرها خواهد رسید.

مدل کوراموتو بر روی شبکه‌های پیچیده^{۱۹}

برای این که از مدل نوسانگرهای کوراموتو در شبکه‌های پیچیده استفاده کنیم، نیاز داریم رابطه ۱.۲ را بازنویسی کنیم، به طوری که دربرگیرنده ماتریس اتصال \mathbf{A} ^{۲۰} (ماتریس مجاورت) شبکه نیز باشد:

$$\dot{\theta}_i = \omega_i + \sum_j \sigma_{ij} a_{ij} \sin(\theta_j - \theta_i) \quad (i = 1, \dots, N), \quad (6.2)$$

که در آن σ_{ij} ها ضرایب اتصال میان جفت نوسانگرهای متصل به هم و a_{ij} ها درایه‌های ماتریس اتصال می‌باشند. مدل اصلی کوراموتو با قرار دادن $\forall i \neq j, a_{ij} = 1$ و $\sigma_{ij} = K/N$ به دست می‌آید.

۲.۱.۲ مدل‌های همراه با پالس

به صورت موازی با مدل کوراموتو، رویکرد دیگری برای بیان پدیده همزمانی در شبکه‌ها به وجود آمده که فعل و انفعال میان اجزای آن بر اساس یک پالس صورت می‌گیرد. ایده اصلی این مدل‌ها بهره‌گیری

^{۱۸}critical coupling

^{۱۹}complex networks

^{۲۰}connectivity matrix

از خاصیت ادغام و آتش^{۲۱} یک نورون است. به این صورت که در این مدل‌ها از نوسانگرهای ادغام و آتش^{۲۲} (IFO) استفاده می‌شود. در این بخش ساختار یک سیستم IFO را شرح می‌دهیم. فاز هر نوسانگر i بر حسب زمان خطی است یعنی $d\phi_i(t)/dt = 1$ در صورتی که اختلال خارجی‌ای وجود نداشته باشد. اگرچه زمانی که نوسانگر i به آستانه $\phi_i(t) = 1$ برسد، یک سیگنال (پالس) به سایر نوسانگرهایی که به آن متصلند ارسال می‌کند و به حالت $\phi_i(t) = 0$ می‌رسد. این پالس می‌تواند آنی و یا با یک تأخیر زمانی τ باشد، و هنگامی که به سایر نوسانگرها می‌رسد یک جهش در فاز را ایجاد می‌کند $\phi_j \rightarrow \phi_j + \Delta(\phi_j)$. تأثیرات توپولوژیکی شبکه‌ای از IFOها بر روی همزمانی همانند مدل کوراموتو است، منتها با پیچیدگی بسیار بیشتر. مشکل اصلی در این مدل این است که دینامیک موجود ایجاد یک عدم پیوستگی در متغیرها می‌کند که باعث پیچیدگی معادلات می‌شود.

تمامی کارهایی که بر روی این مدل انجام شده دارای این فرض است که ضریب اتصال میان نوسانگرها ثابت است، و تنها منبع پیچیدگی ساختاری در این مدل‌ها ماتریس اتصال می‌باشد. در [۵۲] نشان داده شده است که در شبکه‌های همراه با پالس با اتصالات پیچیده (غیربدیهی)، ناهمگنی ضریب اتصال باعث ایجاد یک الگوی آتش متناوب^{۲۳} در میان نوسانگرها می‌شود، که این در واقع معادل همزمانی عمومی^{۲۴} است. ضریب اتصال ناهمگن دارای یک آستانه است که بعد از آن الگوهای آتش متناوب به حالت‌های غیرهمزمان نامتناوب تبدیل می‌شوند. در نهایت می‌توان گفت که میزان قابل توجهی از پیچیدگی در رابطه میان نوسانگرهای همراه با پالس نیاز است تا شاهد الگوهای منظمی باشیم. اگرچه بعد از گذشت از ناحیه بحرانی پیچیدگی شبکه، حالت‌های غیرهمزمان نامتناوب بر دینامیک سیستم چیره می‌شوند [۵۳].

۳.۱.۲ نقشه‌های متصل به هم

نقشه‌ها یک نمایش ساده از سیستم‌های دینامیکی با رفتار بی‌نظم^{۲۵} می‌باشند. در نگاه اول آن‌ها می‌توانند در جایگاه نسخه‌های گسسته نوسانگرهای پیوسته باشند. جمعیت‌های متشکل از اتصال چنین سیستم‌های دینامیکی ساده‌ای با توجه به توانایی بالای آن‌ها برای خودساماندهی^{۲۶} (قابلیت یادگیری) به نسبت

^{۲۱}integrate-and-fire

^{۲۲}Integrate-and-Fire Oscillators

^{۲۳}periodic firing pattern

^{۲۴}global synchrony

^{۲۵}chaotic

^{۲۶}self-organization

کیفیت رفتار عمومی‌شان (موفقیت یادگیری)، مورد مطالعه و توجه محققین قرار گرفتند. در نگاه عملی، کاربرد نقشه‌های متصل به هم، در حجم گسترده‌ای از امور ظاهر شده است. از این دسته می‌توان به دینامیک سیالات و آشفستگی بورس یا سیستم‌های بوم‌شناسی^{۲۷} اشاره کرد [۵۳]. از آن جایی که امروزه می‌دانیم این سیستم‌ها دارای ساختار پیچیده هستند، پس جمعیت‌های متشکل از نقشه‌هایی که در یک شبکه پیچیده به همدیگر متصل هستند یک کاندیدای طبیعی برای مطالعه همزمانی می‌باشند.

نقشه‌های متصل به هم به صورت گسترده در شبکه‌های منظم، درخت‌ها و همچنین در شبکه‌های اتصال کامل بررسی شده‌اند. اولین تلاش برای تعریف روش اتصال میان آن‌ها در [۵۴] انجام شد. در مدل ارائه شده واحدهای تشکیل دهنده سیستم نقشه‌های منطقی^{۲۸} بودند، که هر کدام به طور تصادفی به دقیقاً k تا از نقشه‌های دیگر متصل بودند (چند یال بین دو گره و یال از گره به خودش نیز مجاز بودند). رابطه تکامل سیستم به این صورت مقرر شده بود:

$$x_i(t+1) = \frac{1}{k} \sum_j a_{ij} f(x_j(t)). \quad (۷.۲)$$

که در آن $x_i(t)$ وضعیت جزء i -ام در زمان t است و $f(x)$ تابع تأثیر سیستم است، a_{ij} نیز درایه سطر i و ستون j از ماتریس مجاورت سیستم است. با تحلیل پایداری بر حسب مقادیر ویژه ماتریس مجاورت شبکه ثابت شده است که برای نقشه منطقی با $k > 4$ همزمانی در سیستم رخ می‌دهد. همچنین زمانی که سیستم نیاز دارد تا به همزمانی برسد با ضریب k و اندازه سیستم، کاهش می‌یابد. نشان داده شده است که با تغییر کوچکی، همزمانی این مدل در شبکه‌های واتس-اشتروگاتس^{۲۹} (WS) دست یافتنی است.

یک مدل دیگر برای به کار بردن در شبکه‌های با دینامیک غیرمنظم [۵۵]، که بر روی یک شبکه جهان کوچک^{۳۰} (SW) تحلیل شده، به صورت زیر می‌باشد:

$$\theta_i(t+1) = (1-\sigma)f(\theta_i(t)) + \frac{\sigma}{\kappa + \kappa} \sum_{j=1}^N a_{ij} f(\theta_j(t)), \quad (۸.۲)$$

که در آن κ تعداد میانبرها در شبکه می‌باشد، و σ ضریب اتصال است. هر واحد شبکه خروجی‌اش از یک نقشه سینوسی می‌آید یعنی:

$$f(\theta) = \theta + \Omega - \frac{K}{2\pi} \sin(2\pi\theta) \quad (mod \ 1), \quad (۹.۲)$$

^{۲۷}ecological systems

^{۲۸}logistic maps

^{۲۹}Watts-Strogatz

^{۳۰}small world

که رابطه فوق یک مثال ساده برای توصیف دینامیک یک نوسانگر فاز است که توسط نیرویی متناوب و وابسته به زمان برانگیخته می‌شود. در این جا K ضریب ثابتی است که به دامنه نیروی خارجی وابسته است و $0 \leq \Omega < 1$ نسبت میان فرکانس طبیعی نوسانگر و فرکانس نیروی وارد شده است. کارهای دیگری نیز در زمینه نقشه‌های متصل به هم انجام شده است. اما به طور خلاصه اکثر این کارها با مدل مشخصی از نقشه‌های متصل به هم سروکار دارند (نقشه‌های منطقی، نقشه‌های سینوس-دایره‌ای^{۳۱}، نقشه‌های درجه دو^{۳۲}، ...). همین طور دیده شده که در برخی موارد نه تنها شرایط پایداری محلی حالت همزمانی کامل قابل بدست آوری است، بلکه شرایط همزمانی مستقل از شرایط اولیه نیز قابل بیان است. در حالت کلی اضافه کردن میانبرها در شبکه‌های منظم باعث بهبود همزمانی می‌شود. حتی برخی موارد نیز وجود دارد که همزمانی حاصل نمی‌شود مگر با اضافه کردن پارامترهای تصادفی به سیستم.

۲.۲ تعاریف موجود برای همزمانی در شبکه‌های پیچیده

برای همزمانی در شبکه‌های پیچیده تعاریف و معیارهای متفاوتی وجود دارد. در این بخش قبل از بیان آن‌ها، این معیارها را به دو دسته کلی تقسیم می‌کنیم:

۱.۲.۲ معیارهای سراسری

این دسته از معیارها [۵۶] بیانگر مفهوم همزمانی تمامی گره‌ها در شبکه می‌باشند. بدیهی است معیاری که بخواهد چنین کاری انجام دهد باید همراه با بودن همه فازها را در نظر بگیرد، از این رو معروفترین معیار برای این کار پارامتر نظم سراسری^{۳۳} یا همان $r(t)$ می‌باشد که از رابطه زیر بدست می‌آید:

$$r(t)e^{i\phi(t)} = \frac{1}{N} \sum_{j=1}^N e^{i\theta_j(t)} \quad (10.2)$$

همان‌طور که دیده می‌شود مجموع سمت راست برابر با یک عدد مختلط است. در صورتی که همه فازها با یکدیگر برابر باشند یعنی $\theta_j(t) = \theta$ ، عبارت سمت راست با $e^{i\theta}$ برابر خواهد بود و در نتیجه $r(t) = 1$. به طور مقابل اگر فازهای نوسانگرهای شبکه طوری پخش باشند که در مجموع سمت راست همدیگر

^{۳۱}sine-circle maps

^{۳۲}quadratic maps

^{۳۳}global order parameter

را خنثی کنند، آنگاه $r(t) = 0$ خواهد بود. در حالت اول همزمانی به صورت کامل و در حالت دوم عدم همزمانی به صورت کامل صورت گرفته است.

یک معیار دیگر برای بررسی همزمانی در شبکه‌های دینامیکی پیچیده، هنگامی است که تعداد پارامترها زیاد می‌شود. در این موقع می‌توان از تابعی به نام تابع پایداری برجسته^{۳۴} استفاده کرد. ثابت می‌شود که اگر از این تابع استفاده کنیم معیاری که برای همزمانی یک شبکه اهمیت پیدا می‌کند نسبت λ_N/λ_2 می‌باشد، که در آن λ_2 و λ_N به ترتیب برابر با دومین و آخرین مقدار ویژه بزرگ ماتریس لاپلاسیان گراف اتصال است. به بیان دیگر هر چه مقدار عبارت λ_N/λ_2 برای یک شبکه کمتر باشد، همزمانی در آن بهتر می‌باشد.

معیار دیگری که برای همزمانی در شبکه‌های نوسانگرها وجود دارد، مربوط به زمانی است که می‌خواهیم با هزینه کمتری به همزمانی در یک شبکه برسیم، از این رو تنها مقدار λ_2 از ماتریس لاپلاسیان گراف اتصال برای ما اهمیت دارد. به این کمیت **اتصال جبری**^{۳۵} یک گراف گفته می‌شود. در این حالت می‌گوییم گرافی که اتصال جبری بیشتری داشته باشد دارای خاصیت‌های همزمانی بهتری است. یک معیار مطرح شده دیگر برای این امر استفاده از زمان لازم برای رسیدن به همزمانی در شبکه است. به این صورت که کمیت خطای میانگین همزمانی^{۳۶} در یک شبکه در زمان t به صورت زیر تعریف می‌شود

$$E(t) = \frac{2}{N(N-1)} \sum_{i < j} ||x_i(t) - x_j(t)||^2 \quad (11.2)$$

که در آن $x_i(t)$ نشان دهنده خصوصیت محلی (فاز) نوسانگر i -ام در شبکه در زمان t می‌باشد. در این مدل بعد از مشخص کردن یک آستانه برای خطای میانگین همزمانی، با روش‌های سعی به کم کردن این خطا در شبکه می‌شود و زمانی که صرف می‌شود تا خطا به آستانه مورد نظر برسد یک معیار برای همزمانی در شبکه در نظر گرفته می‌شود.

^{۳۴}master stability function

^{۳۵}algebraic connectivity

^{۳۶}average synchronization error

۲.۲.۲ معیارهای محلی

در این بخش ابتدا به بیان تعریف رسمی همزمانی دو نوسانگر می‌پردازیم. دو نوسانگر O_n و O_m را همزمان می‌گوییم اگر مشتق فاز آن‌ها به صورت مجانبی^{۳۷} یکی باشند:

$$\lim_{t \rightarrow +\infty} \left[\frac{d\theta_n}{dt}(t) - \frac{d\theta_m}{dt}(t) \right] = 0 \quad (۱۲.۲)$$

که در آن $\theta_n(t)$ فاز نوسانگر n -ام در زمان t می‌باشد. به رخ دادن رابطه فوق به طور اصطلاح قفل شدن فاز^{۳۸} دو نوسانگر گفته می‌شود. یکی از مشکلاتی که این رابطه در عمل دارد در دست نبودن زمانی بی‌نهایت است. از این رو برای حل این مشکل تعاریف جدید دیگری مطرح شده‌اند.

یک معیار دیگر برای همزمانی دو نوسانگر در یک شبکه پیچیده که مشکل گفته شده را ندارد، پارامتر نظم محلی^{۳۹} است:

$$\rho_{nm} = \langle \cos[\theta_n(t) - \theta_m(t)] \rangle, \quad (۱۳.۲)$$

که در آن نماد $\langle \rangle$ نشانه مقدار متوسط بر روی تمامی حالت‌های اولیه متفاوت است. مفهوم رابطه فوق همبستگی میان یک زوج نوسانگر است. از روی این رابطه یک ماتریس دودویی اتصال بدست می‌آید:

$$\mathcal{D}_t(T)_{ij} = \begin{cases} 1, & \rho_{ij}(t) > T \\ 0, & \rho_{ij}(t) < T, \end{cases} \quad (۱۴.۲)$$

که در آن آستانه T داده شده است. از ماتریس فوق عموماً برای شناسایی ساختار شبکه و جامعه در شبکه‌های پیچیده استفاده شده است [۵۷، ۵۸، ۵۹]. یکی از مشکلاتی که این روش اخیر دارد لحظه‌ای بودن همزمانی است و این که در عمل ممکن است دو نوسانگر بارها همزمان و غیرهمزمان شوند. همچنین برخی از مثال‌هایی را که دو نوسانگر دارای فرکانس محدود و نزدیک به هم هستند با این مدل قابل توجه نیست.

تعریف دیگری از همزمانی برپایه تعریف اولیه (قفل شدن فازها) می‌باشد، با این تفاوت که در آن سعی شده مشکل محدود بودن زمان را حل کند. به این صورت که دو نوسانگر را ϵ -شبه همزمان^{۴۰} می‌گویند اگر داشته باشیم:

$$Var[\sin(\Phi_n - \Phi_m)] < \epsilon, \quad 0 < \epsilon \ll 0.5 \quad (۱۵.۲)$$

^{۳۷}asymptotically

^{۳۸}phase-locked

^{۳۹}local order parameter

^{۴۰} ϵ -quasi-synchronized

که در آن Φ_m و Φ_n نمایانگر سری‌های زمانی فاز دو نوسانگر می‌باشد. در تعریف اخیر مشکل محدود بودن زمان حل شده است. همچنین در [۵] به صورت عددی نشان داده شده است که با این تعریف، دو نوسانگری که دارای فرکانس محدود و نزدیک به هم می‌باشند نیز با انتخاب ϵ مناسب شبه همزمان خواهند بود.

۳.۲ روش‌های بهبود همزمانی

علاوه بر این، روش‌هایی برای افزایش قابلیت همزمانی در شبکه‌های پیچیده وجود دارند که در این بخش به آن‌ها اشاره می‌کنیم. قبل از بیان روش‌ها باید متذکر شویم که برای بهبود همزمانی نیاز به یک معیار داریم، معیارهای بهبود همزمانی در واقع به تعریف همزمانی در شبکه برمی‌گردد. از این روش‌هایی که برای بهبود همزمانی مطرح شده‌اند در ابتدا برای تعریف همزمانی از یکی از تعاریف موجود در بخش ۲.۱ استفاده می‌کنند. به طور کلی می‌توان این روش‌ها را به چهار دسته زیر تقسیم کرد:

۱. اضافه کردن یال به شبکه، به صورتی که به شبکه موجود تعدادی یال اضافه می‌کنیم به طوری که معیار همزمانی مورد نظر، که معمولاً نسبت λ_N/λ_2 است، افزایش یابد. در این روش‌ها مسأله اصلی ارائه الگوریتمی است که با کمترین تعداد یال بتوانیم به بیشترین مقدار همزمانی را افزایش دهیم.

۲. وزن دادن به یال‌های شبکه، این روش اغلب در شبکه‌های وزن‌دار استفاده می‌شود. یک روش اثبات شده برای این کار استفاده از معیار مرکزیت میانی^{۴۱} می‌باشد. به این صورت که این الگوریتم‌ها تمایل به اضافه کردن یال‌های با مرکزیت میانی بیشتر به شبکه را دارند.

۳. یک روش مطرح دیگر در این زمینه، استفاده از الگوریتم‌های سیم‌کشی مجدد^{۴۲} است. این الگوریتم‌ها معمولاً در مواقعی استفاده می‌شوند که محدودیتی برای تعداد یال‌های شبکه داریم و نمی‌توان به دلخواه به شبکه یال اضافه کرد. از این رو در ازای حذف هر یال یک یال جدید به شبکه اضافه می‌شود و در واقع یک یال را در ابتدا حذف و آن را دوباره با یک سیاست جدید در شبکه قرار می‌دهیم.

^{۴۱}betweenness centrality

^{۴۲}rewiring

۴. اضافه کردن تأخیر زمانی به یال‌های شبکه نیز یکی از روش‌هایی است که برای افزایش همزمانی در شبکه‌ها تأثیر به سزایی دارد.

فصل ۳

مدل‌های پیشین

در این بخش به بررسی مدل‌های یادگیری ارائه شده برگرفته از شبکه‌های عصبی و شبکه نوسانگرهای عصبی می‌پردازیم. در ادامه با صرف نظر از مدل‌های مشابه به بیان آن دسته از مدل‌ها می‌پردازیم که نتایج قابل توجه و رویکردهای متمایزی داشته‌اند. این مدل‌ها در سه دسته اصلی تقسیم‌بندی کرده‌ایم:

- ۱ - مدل‌هایی که یادگیری در آن‌ها برپایه یادگیری اتصالات سیناپسی در شبکه می‌باشند، ۲ - مدل‌هایی که یادگیری در آن‌ها برپایه شناسایی خصوصیات نودهای شبکه عصبی (معمولاً تابع فعال‌سازی^۱ یک نورون یا فرکانس طبیعی یا لحظه‌ای یک نوسانگر) می‌باشند، ۳ - مدل‌های ترکیبی، که هم به یادگیری اتصالات سیناپسی و هم به یادگیری خصوصیات نودهای شبکه عصبی می‌پردازند.

۱.۳ مدل‌های یادگیری مبتنی بر شناسایی اتصالات سیناپسی

در این بخش به بررسی مدل‌های یادگیری می‌پردازیم که اولاً متشکل از یک شبکه پیچیده یا یک شبکه نوسانگرهای عصبی باشند، ثانیاً یادگیری در این مدل‌ها با تغییر اتصالات میان اجزای تشکیل دهنده شبکه (نورون‌ها یا نوسانگرها) صورت می‌گیرد. به بیان دیگر در این مدل‌ها دانش یادگرفته شده و ذخیره شده در شبکه در اتصالات سیناپسی ذخیره می‌شود. نکاتی که مدل‌های مختلف را در این بخش متمایز می‌کند، در ابتدا معماری شبکه، معادلات نورون‌ها و قانون یادگیری اتصالات سیناپسی است. همچنین

^۱activation function

برخی مدل‌ها که برای کاربردهای خاصی طراحی شده‌اند دارای معماری و معادلات خاصی هستند که آن کاربرد را توجیه کنند. در ادامه به اختصار به برخی از این مدل‌ها اشاره می‌کنیم.


۱.۱.۳ مدل‌های مبتنی بر شبکه‌های عصبی چند لایه [۱، ۲]

در این بخش به توضیح شبکه‌های عصبی، خصوصیات آن‌ها و خلاصه کارهای انجام شده با هدف شناسایی الگو می‌پردازیم. شبکه‌های عصبی مصنوعی که به اختصار به آن‌ها شبکه‌های عصبی گفته می‌شود، تشکیل شده از نورون‌های مصنوعی به هم متصل هستند که یا برای فهمیدن شبکه‌های عصبی زیستی و یا برای حل مسائل هوش مصنوعی بدون نیاز به ساخت یک مدل از یک سیستم زیستی واقعی، به کار می‌روند. با توجه به پیچیدگی بسیار زیاد شبکه‌های عصبی واقعی، شبکه‌های عصبی مصنوعی سعی بر خلاصه‌سازی این پیچیدگی و تمرکز بر بخش پراهمیت‌تر آن از دیدگاه پردازش اطلاعات دارند. یک شبکه عصبی از دیدگاه یک سیستم انطباقی^۲ یک پردازنده موازی توزیع شده است که تشکیل شده از تعداد زیادی واحدهای محاسباتی ساده با خاصیت ذخیره اطلاعات و استفاده از آن. این پردازنده از دو جهت شبیه مغر می‌باشد:

۱. در طی یک فرایند یادگیری دانش از محیط بیرونی داخل شبکه ذخیره می‌شود.
 ۲. اتصالات بین نورونی به نام وزن‌های سیناپسی، اجزایی از شبکه هستند که برای ذخیره کردن دانش کسب شده استفاده می‌شوند.
- تفاوت شبکه‌های عصبی متفاوت در قوانین یادگیری آن‌ها، نوع یادگیری اعم از نظارتی، بدون نظارت و ... و همچنین نوع مسأله‌ی مورد نظر می‌باشد. یکی دیگر از خاصیت‌های اصلی شبکه‌های عصبی خاصیت تقریب زندگی عمومی است که این قدرت را به شبکه عصبی می‌دهد که به صورت تئوری می‌تواند به مقدار دلخواه به هر تابعی نزدیک شود.
- یک شبکه عصبی پرکاربرد به نام پرسپترون چندلایه^۳ تشکیل شده از چند لایه رأس که نمایانگر نورون‌ها در شبکه می‌باشند و یال‌های موجود بین هر دو لایه متوالی که نمایانگر وزن‌های سیناپسی هستند. ورودی این شبکه به نورون‌های لایه اول و خروجی آن از نورون‌های لایه آخر گرفته می‌شود. شکل ۳
۱. یک شمای کلی از شبکه‌های عصبی چندلایه نشان می‌دهد. در طی مراحل یادگیری وزن یال‌های

^۲adaptive system

^۳multilayer perceptron



شکل ۱.۳: نمونه‌ای از یک پرسپترون چندلایه، تشکیل شده از لایه ورودی، لایه میانی (پنهان) و لایه خروجی

شبکه عصبی با هدف بهینه‌سازی تابع هدف (که معمولاً میانگین مربع خطا می‌باشد) با الگوریتم یادگیری مفروض (که معمولاً پس‌انتشار خطا^۴ می‌باشد) تغییر کرده و به حالت نهایی می‌رسند. این خطا برای رأس j -ام از خروجی و برای n -امین داده مجموعه آموزش به صورت عبارت $e_j(n)$ نشان داده می‌شود که از رابطه زیر پیروی می‌کند:

$$e_j(n) = d_j(n) - y_j(n) \quad (۱.۳)$$

که در آن d مقدار مطلوب خروجی و y خروجی تولید شده توسط پرسپترون است. همچنین تصحیح وزن یال‌های شبکه با هدف مینیم کردن مقدار کل خطا:

$$\epsilon(n) = \frac{1}{2} \sum_j e_j^2(n) \quad (۲.۳)$$

و با حرکت در جهت تندترین شیب^۵، رابطه تغییر وزن یال‌ها به این صورت درمی‌آید:

$$\Delta w_{ji}(n) = -\eta \frac{\partial \epsilon(n)}{\partial v_j(n)} y_i(n) = -\eta e_j(n) \phi'(v_j(n)) y_i(n) \quad (۳.۳)$$

که در آن w_{ji} وزن میان دو نورون i -ام و j -ام است و y_i خروجی نورون i -ام می‌باشد. همچنین پارامتر یادگیری است که باید با دقت انتخاب شود که وزن‌ها با سرعت کافی به مقدار مطلوب و بدون تولید نوسانات همگرا شوند.

^۴backpropagation

^۵gradient descent

۲.۱.۳ یادگیری اتصالات در شبکه نوسانگرهای فاز [۳]

در این کار به تحلیل یک سیستم ساده از نوسانگرهای فاز پرداخته شده است که در آن ضرایب اتصالات به صورت دینامیکی یادگرفته می‌شوند. این مدل الهام گرفته از روند یادگیری آواز توسط پرندگان آوازخوان است. به این صورت که یک نوسانگر به عنوان مولد یک نوا^۶ی ساده است و نوسانگرهای برده^۷ را که مسئول محرک‌های متفاوت هستند، مورد هدایت خود قرار می‌دهد. سیگنال هادی از دو مسیر به نوسانگرهای هدایت شده می‌رسد. یکی از آن‌ها یک مسیر مستقیم است. دیگری یک مسیر تقویتی^۸ است، که در آن سیگنال با تأخیر می‌رسد. ضرایب اتصالات میان نوسانگر هادی^۹ و نوسانگرهای برده، از طریق یک قانون یادگیری شبیه قانون هب در طول زمان به دست می‌آیند. همچنین شرایطی که در آن یک نوسانگر هدایت‌شده قادر به قفل شدن با هادی خود خواهد بود مورد بحث قرار گرفته است، و نتایج اختلاف فاز و ضرایب اتصالات تابعی از تأخیر بخش تقویتی خواهد بود. الهام دهنده اصلی این مدل گذرگاه تحریک و تولید صوت در پرندگان آوازخوان است. این گذرگاه در شکل ۲.۳ به نمایش درآمده است. بخش‌های تشکیل دهنده این گذرگاه که مسئول تولید صدا هستند HVC^{۱۰} و RA^{۱۱} می‌باشند. همچنین مسیر دیگری که AFP^{۱۲} نام دارد. و در نهایت رم^{۱۳} و ان ایکس آی تی اس^{۱۴} که ماهیچه‌ها و تنفس پرنده را کنترل می‌کنند. هسته RA شامل نورون‌های محرک^{۱۵} است، که تعدادی از آن‌ها هسته تنفسی را بی‌اثر کرده و تعدادی نیز هسته nXIIts را، که ماهیچه‌ها را به موسیقار^{۱۶} نگاشت می‌کند. این دو جمعیت از نورون‌ها در دو بخش مختلف RA جدا می‌شوند.

با توجه به قابلیت مرتبط کردن خصوصیت‌های یک آهنگ، با مشخصات ماهیچه‌های مورد نیاز برای تولید آن، محققین دریافته‌اند که تولید هجا‌های تکراری نیاز به حرکت چرخه‌ای بازدم، و حرکت چرخه‌ای

^۶rhythm

^۷slave oscillators

^۸reinforcement

^۹driving oscillator

^{۱۰}high vocal center

^{۱۱}robustus nucleus of the archistriatum


^{۱۲}anterior forebrain pathway

^{۱۳}Ram

^{۱۴}nXIIts

^{۱۵}excitatory neurons

^{۱۶}syrinx



شکل ۲.۳: دو نوسانگر نشان دهنده جمعیت نورون‌های هدایت شده (*Ram* و *nXIIIts*) توسط نوسانگر استاد (*HVC*) اعمال استاد را با تأخیرهای متفاوت تکرار می‌کنند. این دو جمعیت از نورون‌ها بخش‌های مختلف تولید آوا هستند: هسته موسیقار (*syringeal nucleus*) و ماهیچه تنفسی (*respiratory muscle*) [۳]

ماهیچه‌های موسیقار^{۱۷} (عضو آوازی پرندگان که در نای آن‌ها قرار دارد) دارد. صدا توسط لبه‌های قرار گرفته در محل اتصال برونش^{۱۸} و ترک^{۱۹} تولید می‌شود، و به طور متناوب مانع جریان هوا می‌شود. مدل ارائه شده خروج نقطه میانی لبه‌ها را از محل تولید صدا توصیف می‌کند (x):

$$\begin{aligned} \frac{dx}{dt} &= y \\ \frac{dy}{dt} &= \epsilon(t)x - Cx^{\gamma}y + B(t)y \end{aligned} \quad (۴.۳)$$

که در آن $\epsilon(t)$ تابع فعالیت ماهیچه‌های شکمی و $B(t)$ تابع فشار برونشی است. این مدل با استفاده از توابع $\epsilon(t)$ و $B(t)$ که به صورت تجربی به دست آمده‌اند، تست شده است. نتایج به دست آمده برای $x(t)$ به مقدار قابل توجهی شبیه نتایج ضبط شده واقعی از داده‌های فیزیولوژیکی می‌باشد.

^{۱۷}syrinx

^{۱۸}bronchii

^{۱۹}tract

۳.۱.۳ بهره‌گیری از قانون یادگیری هب در شبکه نوسانگرهای فاز [۴]

کارهای مختلفی درباره با انتقال فاز ^{۲۰} در یک شبکه نوسانگرهای فاز بر پایه قانون استاندارد یادگیری هب انجام شده است. یکی از این کارها مدل معروف هاپفیلد ^{۲۱} است. اطلاعات مربوط به فاز مختلفی اعم از درون-فازی ^{۲۲} و ضد-فازی ^{۲۳} قابلیت جایگیری در شبکه را دارند. در این مدل با استفاده از تحلیل خودسازگار سیگنال به نویز ^{۲۴} (SC-SNA) نشان داده شده است که ظرفیت حافظه شبکه برابر $\alpha_c = 0.42$ می‌باشد، که البته سرعت بازیابی در آن پایین است.

در این مدل برای نشان دادن رابطه میان نوسانگرهای شبکه از معادله زیر استفاده شده است:

$$\frac{d\phi_i}{dt} = - \sum_{j=1}^N J_{ij} \sin(\phi_i - \phi_j); \quad i = 1, \dots, N \quad (5.3)$$

که در آن N تعداد نوسانگرها، ϕ_i فاز نوسانگر i -ام و J_{ij} وزن اتصال سیناپسی است. در مدل کوک ^{۲۵} ضریب J_{ij} یک مقدار مختلط در نظر گرفته شده که با یک قانون هب تعمیم یافته به دست می‌آید. مدل کوک می‌تواند یک تعمیم چندحالتی شبکه هاپفیلد در نظر گرفته شود. در مدل مطرح شده با استناد به این که وزن سیناپسی مختلط به سادگی در مثال‌های واقعی قابل دست‌یابی نیست، و با هدف بهبود این رابطه، مقدار J_{ij} از رابطه زیر به دست می‌آید:

$$J_{ij} = \frac{1}{N} \sum_{\mu=1}^p \xi_i^\mu \xi_j^\mu, \quad \xi_i^\mu = \exp(i\theta_i^\mu) \quad (6.3)$$

که در آن $\{\theta_i^\mu\}_{i=1, \dots, N, \mu=1, \dots, p}$ الگوهای فازی مورد نظر برای ذخیره در شبکه هستند و به صورت تصادفی با احتمال $1/2$ برابر با 0 یا π خواهند بود.

در این مدل یک پارامتر α به نام نرخ بارکنش ^{۲۶} برابر با $\alpha = p/N$ تعریف شده است. این قانون یادگیری معادل با قانون یادگیری هب در مدل هاپفیلد می‌باشد که در مثال‌های زیستی واقعی نیز مشاهده می‌شود. در واقع مقدار J_{ij} میان دو سلول که همزمان برانگیخته می‌شوند افزایش پیدا می‌کند و در غیر این صورت کاهش می‌یابد.

^{۲۰} phase transition

^{۲۱} Hopfield

^{۲۲} in-phase

^{۲۳} anti-phase

^{۲۴} self-consistent signal-to-noise analysis

^{۲۵} Cook's model

^{۲۶} loading rate

در این مدل پارامتر نظم برای راحتی برابر با

$$m = \sqrt{m_c^2 + m_s^2} \quad (7.3)$$

که در مقادیر m_s و m_c از روابط زیر به دست می‌آیند:

$$m_c^\mu = \frac{1}{N} \sum_i \xi_i^\mu \cos \phi_i, m_s^\mu = \frac{1}{N} \sum_i \xi_i^\mu \sin \phi_i \quad (8.3)$$

در این مدل پس از تحلیل خواص ریاضی آن، با شبیه‌سازی نشان داده شده که ظرفیت ذخیره‌سازی در آن

متناظر با $\alpha_c = 0.42$ می‌باشد که در نقطه تقاطع $m = 0.69$ به دست می‌آید.

۲.۳ مدل‌های یادگیری مبتنی بر شناسایی خصوصیات محلی نوسانگرها

در این بخش به بررسی مدل‌هایی می‌پردازیم که یادگیری در آن‌ها مربوط به خصوصیات محلی نوسانگرها می‌باشد. در این شبکه‌های نوسانگرهای عصبی، اتصالات سیناپسی ثابت فرض می‌شوند و معماری شبکه در طول مراحل یادگیری تغییری نمی‌کند، بلکه این تغییر در خصوصیات محلی نوسانگرها صورت می‌گیرد که عموماً شامل دامنه و فاز یک نوسانگر می‌باشد. انگیزه اصلی موجود در این مدل‌ها استفاده از همزمانی نوسانگرها در شبکه می‌باشد و از آن جایی که این همزمانی با فرکانس طبیعی و فرکانس لحظه‌ای نوسانگرها ارتباط قوی‌تری دارد تا با اتصالات میان آن‌ها، در این مدل‌ها به یادگیری فرکانس طبیعی نوسانگرها پرداخته شده تا بعد از اجرا شدن معادلات شبکه، شبکه حاصل به الگوی مورد نظر نزدیک‌تر باشد. به عبارت دیگر در این مدل‌ها دانش یادگرفته شده در فرکانس طبیعی نوسانگرها ذخیره می‌شود.

۱.۲.۳ مدل مبتنی بر شبه-همزمانی نوسانگرهای فاز [۵]

در این مدل، از شبکه نوسانگرهای فاز مدل کوراموتو استفاده می‌شود. به این صورت که رأس‌های شبکه به دو دسته رأس‌های محرک^{۲۷} و شناسایی^{۲۸} تقسیم می‌شوند. مفهوم موجود در این قسمت از مدل تقسیم قسمت‌های مختلف مغر و فهمیدن چگونگی ارتباط میان دو بخش گیرنده محرک و دهنده پاسخ می‌باشد. به این صورت که ورودی این سیستم، فرکانس طبیعی رأس‌های محرک است و پس از اجرای مدل کوراموتو بر روی شبکه و پایدار شدن فرکانس نوسانگرها، وضعیت فرکانسی نوسانگرهای شناسایی، خروجی سیستم را تعیین می‌کنند. برای بررسی کردن این وضعیت فرکانسی روش‌های مختلفی وجود دارد

^{۲۷}stimulus

^{۲۸}recognition

ولی به هدف وجود استقلال زمانی بهترین روش برای این کار استفاده از شبه-همزمانی است که در رابطه ۱۵.۲ توضیح داده شده است. در نهایت خروجی سیستم برابر با یک ماتریس دودویی خواهد بود که ۰ یا ۱ بودن هر درایه از آن معادل با شبه-همزمانی یا عدم شبه-همزمانی نوسانگرهای مربوط به آن درایه می‌باشد.

الگوریتم ارائه شده در [۵] به صورت زیر می‌باشد:

۱. پارامترها: مجموعه محرک $\{(A_n^s, f_n^s, \phi_n^s(\cdot))\}$ ، فرکانس طبیعی نوسانگرهای شناسایی $\{f_n\}_{n \in G_R}$ ، ضرایب اتصال $\{k_{nm}\}_{n,m}$ و پارامترهای یادگیری $\{\mu_{nm}\}_{n,m}$.

۲. شرایط اولیه: برای $O_n \in G_S$ داریم $\phi_n(\cdot) = \phi_n^s(\cdot)$ و $f_n(\cdot) = f_n$ در غیر این صورت $\phi_n(\cdot)$ به صورت تصادفی از بازه $[0, 2\pi]$ انتخاب می‌شود.

۳. دینامیک مسأله: برای $0 < t \leq T$ داریم:

$$\frac{1}{2\pi} \frac{d\phi_n}{dt} = f_n + \rho_n(t) + \sum_{m=1}^N A_n A_m k_{nm} \sin[\phi_m(t) - \phi_n(t)] \quad (9.3)$$

همچنین برای هر $O_n \in G_R$ داریم:

$$\frac{df_n(t)}{dt} = \sum_{O_m \in G_R} \mu_{nm} \left(\frac{1}{2\pi} \frac{d\phi_m(t)}{dt} - f_n(t) \right) \quad (10.3)$$

که در آن $\phi_n(t)$ فاز نوسانگر n -ام در زمان t و $\rho_n(t)$ نویز اضافه شده به رابطه می‌باشد که در صورت نیاز می‌تواند حذف یا اضافه شود. رابطه ۹.۳ همان رابطه کوراموتو در شبکه‌های پیچیده با اندکی تغییر می‌باشد (همان رابطه ۶.۲). علاوه بر آن، رابطه ۱۰.۳ در واقع سعی دارد فرکانس طبیعی f_n را به فرکانس لحظه‌ای نوسانگر نزدیک‌تر بکند. و در آن پارامترهای یادگیری $\{\mu_{nm}\}_{nm}$ ($\mu_{nm} = \mu_{mn}$) طوری انتخاب می‌شوند که سیستم به سمت الگوی مورد نظر هدایت شود، بدین صورت که اگر نوسانگرهای O_n و O_m قرار است که با یکدیگر همزمان نشوند مقدار $\mu_{nm} > 0$ انتخاب می‌شود، اگر قرار باشد که این دو با یکدیگر همزمان نشوند مقدار $\mu_{nm} < 0$ و اگر همزمانی آن‌ها بی‌اهمیت باشد مقدار $\mu_{nm} = 0$ انتخاب می‌شود.

در نهایت پس از پایدار شدن نوسانات نوسانگرها (که این زمان به صورت تجربی و با توجه به محدوده داده‌های ورودی به دست می‌آید)، با محاسبه شبه-همزمانی دودوی نوسانگرهای شناسایی، خروجی سیستم در قالب یک ماتریس دودویی به دست می‌آید.

شناسایی الگو با استفاده از این شبکه توضیح داده شده به این صورت می‌باشد که ابتدا خروجی داده

آموزش محاسبه می‌شود. سپس خروجی داده آزمون با معیار فاصله همینگ^{۲۹} به نزدیک‌ترین خروجی آموزش نگاشت می‌شود. تعداد نگاشت‌های صحیح برابر با نرخ شناسایی^{۳۰} خواهد بود.

۳.۳ مدل‌های یادگیری ترکیبی

در این بخش به بررسی مدل‌هایی می‌پردازیم که یادگیری در آن‌ها علاوه بر خصوصیات محلی نوسانگرها و یا نورون‌ها، به اتصالات سیناپسی میان آن‌ها نیز برمی‌گردد. در واقع دانش در این شبکه‌ها هم در خصوصیات محلی و هم در خصوصیات سراسری اجزای تشکیل دهنده شبکه که اتصالات سیناپسی باشند، ذخیره می‌شود.

۱.۳.۳ پردازش خصوصیات محلی و سراسری در شبکه نوسانگرهای عصبی

[۶]

در این مدل یک شبکه نوسانگرهای عصبی ارائه شده است که توانایی پردازش محلی و سراسری خاصیت‌های ورودی حسی^{۳۱} را دارد. خصوصیت‌های محلی ورودی در میانگین نرخ افروختگی نورون‌ها قرار دارد و رابطه میان این خصوصیت‌ها قابلیت تنظیم کردن ساختار موقتی خروجی عصبی را دارد.

۱. روابط مربوط به فاز: در این جا برافروختگی نورون‌ها یک فرایند تصادفی در نظر گرفته شده است که توسط احتمال این که نورون r در زمان t برافروخته شود بیان می‌شود. این تابع احتمال $P(r, t)$ ، به فرم زیر در نظر گرفته شده است:

$$P(r, t) = V(r)(1 + \lambda \cos \phi(r, t)) \quad (11.3)$$

که در آن فازهای $\phi(r, t)$ بیانگر الگوی برافروختگی موقت نورون‌ها هستند. ضریب λ مربوط به سهم موقتی تنظیم فعالیت نورون‌ها است. دامنه $V(r)$ میانگین نرخ برافروختگی نرمال شده است بر روی زمان است. اگر هیچ محرکی در ناحیه ادراکی^{۳۲} نورون r نباشد داریم $V(r) = 0$. با وجود یک محرک در میدان، $V(r)$ بر خم میزان نورون^{۳۳} منطبق می‌شود، یعنی $V(r) =$

^{۲۹}Hamming

^{۳۰}recognition rate

^{۳۱}sensory input

^{۳۲}receptive field

^{۳۳}tuning curve of the neuron

$V(\theta(r) - \theta(r'))$ ، که در آن $\theta(r)$ جهت محرک و $\theta(r)$ جهت نورون مورد نظر است.

متغیرهای فاز مربوط به وجوه موقتی فعالیت عصبی از روابط مربوط به شبکه نوسانگرهای فاز متصل به هم با نویز طبیعت می‌کند:

$$\tau \cdot \dot{\phi}(r, t) = \omega \tau + \eta(r, t) - \sum_{r' \neq r} J(r, r') \sin(\phi(r, t) - \phi(r', t)) \quad (12.3)$$

که در آن τ مقیاس زمانی نورونی و ω فرکانس نوسانات نورونی است. در این مدل فرض می‌شود که $\tau \ll 2\pi/\omega \simeq 25ms$ و $\tau \simeq 3ms$ تخمین‌های τ و $2\pi/\omega$ می‌باشد که از آزمایش‌های تجربی به دست آمده‌اند. عبارت $\eta(r, t)$ نمایانگر نویز سفید با واریانس $\langle \eta(r, t) \eta(r', t') \rangle = 2T\tau \cdot \delta_{rr'} \delta(t - t')$ می‌باشد که در آن T اندازه نویز می‌باشد. نویز نشان دهنده نوسانات در ورودی به سلول می‌باشد. ضریب اتصال $J(r, r')$ واسطه میان فعل و انفعال نورون‌های r و r' می‌باشد. در نهایت، مجموع بر روی r' مشخص کننده تمامی نورون‌های درون شبکه است.

۲. معماری اتصالات: تصور بر این است که روابط میان فازهای نورون‌ها حامل اطلاعات درباره مکان و جهت محرک می‌باشد. ادعا بر این است که این رابطه با میانگین فعالیت سلول پیش-سیناپسی و پس-سیناپسی ارتباط دارد، یعنی:

$$J(r, r') = V(r)W(r, r')V(r') \quad (13.3)$$

که در آن $W(r, r')$ بیان‌کننده معماری اتصالات است و مستقل از محرک خارجی می‌باشد. یک نکته مهم این مدل تفسیر رابطه میان نورون‌هایی است که در یک ناحیه ادراکی قرار دارند و نورون‌هایی که در یک ناحیه ادراکی قرار ندارند. در این جا یک نوعی معماری فرض شده است که در آن نورون‌ها در دسته‌هایی طبقه‌بندی شده‌اند که مشابه ابرستون^{۳۴}های بخش بصری کرتکس^{۳۵} هستند. این نورون‌ها در فضای مختصات یک دسته برچسب‌گذاری شده‌اند که با R نشان می‌دهیم، و جهت آن‌ها که با θ نمایش داده می‌شود که به طور یکنواخت در هر دسته پخش شده است. هر نورون با سلول‌های که در یک دسته قرار دارند از طریق اتصالات با برد کم مرتبط است:

$$W_{RR}(\theta, \theta') = W_S/N \quad (14.3)$$

^{۳۴}hypercolumn

^{۳۵}visual cortex

که در آن N تعداد نورون‌های داخل یک دسته است که توسط یک محرک فعال می‌شوند. این به رابطه میان نورون‌های فعال درون یک ناحیه ادراکی اجازه می‌دهد که تنها تغییر کوچکی که تابعی از جهت‌هایشان است، داشته باشند. نورون‌های دو دسته مختلف از طریق اتصالات با برد زیاد یا یکدیگر مرتبط هستند:

$$W_{RR'}(\theta, \theta') = W_L F(\theta - \theta') / N^2, \quad R \neq R' \quad (15.3)$$

در رابطه فوق مفروض است که $W_{RR'}(\theta, \theta')$ به جدایی مکانی میان دسته‌ها ارتباطی ندارد. تابع $F(\theta - \theta')$ به این صورت انتخاب می‌شود که رابطه میان فاز دسته‌های مختلف وابستگی قابل توجهی به جهت‌های محرک دارد. نسبت قدرت اتصالات با برد زیاد به اتصالات با برد کم برابر $1/N \ll 1$ می‌باشد. این نسبت تضمین می‌کند که رابطه میان نورون‌های یک ناحیه ادراکی مستقل از خاصیت‌های سراسری^{۳۶} محرک دارد.

به طور خلاصه در این مدل نورون‌هایی که در ناحیه ادراکی قرار دارند از طریق اتصالات با بازخورد قوی به یکدیگر متصل هستند، در حالی که نورون‌هایی که در ناحیه‌های ادراکی متفاوت قرار دارند با اتصالات خاص و ضعیفی به یکدیگر متصلند. این الگوی اتصال مقلد قشر بینایی مغز^{۳۷} است. این مدل در زمینه پردازش قشر بینایی که برای جهت‌یابی کدگذاری شده، مورد مطالعه و بررسی قرار گرفته و نتایج تئوری آن با نتایج به دست آمده از قشر بینایی مغز گره مقایسه شده است. همچنین توان محاسباتی این مدل برای قطعه‌بندی نیز مورد بحث قرار گرفته است.

۲.۳.۳ شبکه نوسانگرهای فاز به عنوان یک مدل عصبی برای شایسته‌سازی

محرک- پاسخ [۷]

در این مقاله با استفاده از همزمانی نورون‌ها در شبکه نوسانگرهای فاز متصل به هم تحت مدل کوراموتو، سعی بر ارائه مدلی از نوسانگرهای عصبی شده که بر پایه شواهد نوروفیزیولوژیکی بنا شده است. سپس این مدل را بر روی مدل‌های یادگیری نظریه رفتاری محرک- پاسخ^{۳۸} تأیید کرده است. برای این کار از یک شبکه متشکل از سه نوسانگر کوراموتو برای مدل‌سازی زنجیره پاسخ‌ها^{۳۹} استفاده شده است. در

^{۳۶}global

^{۳۷}visual cortex (primary visual cortex)

^{۳۸}behavioral stimulus-response theory

^{۳۹}continuum of responses

این راستا به شبیه‌سازی‌های عددی و تحلیل مدل کوراموتو با سه نوسانگر، همچنین بررسی نقاط پایداری برای شرایط مختلف اتصالات پرداخته شده است. در ادامه به بیان مختصر معادلات ارائه شده در این مدل و قوانین یادگیری مربوط به آن‌ها به همراه فرض‌های وارد شده می‌پردازیم.

منظور از یک نوسانگر عصبی، گروهی از نورون‌های به هم پیوسته است که برانگیختگی آن‌ها ارتباط و تناوب نزدیکی با همدیگر دارد. در ادامه برای نشان دادن چگونگی محاسبه انتخاب تصادفی پاسخ‌ها از یک محرک s ، از یک شبکه نوسانگرهای فاز با سه نوسانگر استفاده می‌شود. برای این کار سه نوسانگر همساز s ، r_1 و r_2 را در نظر بگیرید. به دلیل ساده‌تر شدن معادلات فرض کنید این سه نوسانگر دارای فرکانس طبیعی یکسان ω و دامنه یکسان می‌باشند. داریم

$$\begin{aligned} s(t) &= A \cos(\omega, t) = A \cos(\varphi_s(t)) \\ r_1(t) &= A \cos(\omega, t + \delta\phi_1) = A \cos(\varphi_{r_1}(t)) \\ r_2(t) &= A \cos(\omega, t + \delta\phi_2) = A \cos(\varphi_{r_2}(t)) \end{aligned} \quad (۱۶.۳)$$

که در آن $s(t)$ ، $r_1(t)$ و $r_2(t)$ نمایانگر نوسانات همساز هستند. $\varphi_s(t)$ ، $\varphi_{r_1}(t)$ و $\varphi_{r_2}(t)$ فاز آن‌ها، $\delta\phi_1$ و $\delta\phi_2$ مقادیر ثابت A دامنه آن است. نکته قابل توجه در این جا این است که چون تمام نوسانگرها دارای دامنه یکسان هستند، دینامیک مسئله تنها با فاز آن‌ها قابل بیان است. این فرض که نوسانگرهای محرک و پاسخ دارای فرکانس یکسان باشند ضروری نیست اما در این مدل برای ساده‌تر شدن تحلیل در نظر گرفته شده است و این باعث تمرکز بیشتر بر روی پدیده قفل شدن فاز می‌شود. در این مدل همچنین فرض شده که ضرایب اتصالات متقارن است و با توجه به این که در نظریه محرک-پاسخ ارائه شده نوسانگرهای پاسخ مستقل در نظر گرفته شده‌اند، در مدل ارائه شده اتصالاتی میان نوسانگرهای پاسخ وجود ندارد. یک فرض دیگر که در این مدل وجود دارد و کمی در تناقض با شرایط مفروض در مدل کوراموتو با اتصالات ضعیف می‌باشد، یادگیری تقویتی اتصالات میان نوسانگرهاست. چرا که در یادگیری باید وزن این اتصالات تقویت شود و این تقویت کمی در تناقض با ضعیف بودن این اتصالات از همان ابتدا می‌باشد.

زمانی که نوسانگرهای محرک و پاسخ فعال می‌شوند، فاز هر نوسانگر از یک توزیع نرمال با میانگین صفر (یعنی $\bar{\varphi} = 0$) و انحراف معیار σ_φ بازنشانده می‌شود، که در این جا برای تمامی نوسانگرهای محرک و پاسخ یکسان می‌باشد. (دقت کنید که فرض صفر بودن میانگین از کلیت مسئله نمی‌کاهد چرا که در عمل این اختلاف میان فازهاست که اهمیت دارد) در نتیجه مستقل از تعداد نوسانگرها داریم

$$f(\varphi_i) = \frac{1}{\sigma_\varphi \sqrt{2\pi}} \exp\left(-\frac{\varphi_i^2}{2\sigma_\varphi^2}\right) \quad (۱۷.۳)$$

که در آن $i = s_j, r_1, r_2$ می‌باشند. پس از نمونه‌برداری محرک‌ها، نوسانگرهای فعال در هر بازه زمانی

$$\frac{d\varphi_i}{dt} = \omega_i - \sum_{i \neq j} k_{ij} \sin(\varphi_i - \varphi_j + \delta_{ij}) \quad (18.3)$$

که در آن k_{ij} ضریب اتصال میان نوسانگرهای i و j ، و δ_{ij} ‌ها یک ماتریس پادتقارنی نمایانگر اختلاف فازهای موجود در مدل است، و i و j می‌توانند هر کدام از s ، r_1 و r_2 باشند.

برای N نوسانگر محرک s_j که $j = 1, \dots, N$ ، رابطه ۱۸.۳ را برای حالت خاص سه نوسانگر s_j ، r_1 و r_2 بازنویسی می‌کنیم. در این روابط جدید نماد k_j^E را برای وزن اتصالات حالت برانگیخته 40 و k_{ij}^I را برای وزن اتصالات حالت بازدارنده 41 در نظر گرفته‌اند:

$$\begin{aligned} \frac{d\varphi_{s_j}}{dt} = & \omega_{s_j} - k_{s_j, r_1}^E \sin(\varphi_{s_j} - \varphi_{r_1}) \\ & - k_{s_j, r_2}^E \sin(\varphi_{s_j} - \varphi_{r_2}) \\ & - k_{s_j, r_1}^I \sin(\varphi_{s_j} - \varphi_{r_1}) \\ & - k_{s_j, r_2}^I \sin(\varphi_{s_j} - \varphi_{r_2}) \\ & - K \cdot \sin(\varphi_{s_j} - \omega_e t) \end{aligned} \quad (19.3)$$

$$\begin{aligned} \frac{d\varphi_{r_1}}{dt} = & \omega_{r_1} - k_{r_1, s_j}^E \sin(\varphi_{r_1} - \varphi_{s_j}) \\ & - k_{r_1, r_2}^E \sin(\varphi_{r_1} - \varphi_{r_2}) \\ & - k_{r_1, s_j}^I \sin(\varphi_{r_1} - \varphi_{s_j}) \\ & - k_{r_1, r_2}^I \sin(\varphi_{r_1} - \varphi_{r_2}) \\ & - K \cdot \sin(\varphi_{r_1} - \omega_e t - \delta\varphi) \end{aligned} \quad (20.3)$$

$$\begin{aligned} \frac{d\varphi_{r_2}}{dt} = & \omega_{r_2} - k_{r_2, s_j}^E \sin(\varphi_{r_2} - \varphi_{s_j}) \\ & - k_{r_2, r_1}^E \sin(\varphi_{r_2} - \varphi_{r_1}) \\ & - k_{r_2, s_j}^I \sin(\varphi_{r_2} - \varphi_{s_j}) \\ & - k_{r_2, r_1}^I \sin(\varphi_{r_2} - \varphi_{r_1}) \\ & - K \cdot \sin(\varphi_{r_2} - \omega_e t - \delta\varphi + \pi) \end{aligned} \quad (21.3)$$

⁴⁰ excitatory

⁴¹ inhibitory

وزن اتصالات حالت برانگیخته با توجه به معادلات زیر تقویت می‌شود:

$$\frac{dk_{s_j, r_1}^E}{dt} = \epsilon(K.) [\alpha \cos(\varphi_{s_j} - \varphi_{r_1}) - k_{s_j, r_1}^E] \quad (22.3)$$

$$\frac{dk_{s_j, r_2}^E}{dt} = \epsilon(K.) [\alpha \cos(\varphi_{s_j} - \varphi_{r_2}) - k_{s_j, r_2}^E] \quad (23.3)$$

$$\frac{dk_{r_1, r_2}^E}{dt} = \epsilon(K.) [\alpha \cos(\varphi_{r_1} - \varphi_{r_2}) - k_{r_1, r_2}^E] \quad (24.3)$$

$$\frac{dk_{r_1, s_j}^E}{dt} = \epsilon(K.) [\alpha \cos(\varphi_{r_1} - \varphi_{s_j}) - k_{r_1, s_j}^E] \quad (25.3)$$

$$\frac{dk_{r_2, s_j}^E}{dt} = \epsilon(K.) [\alpha \cos(\varphi_{r_2} - \varphi_{s_j}) - k_{r_2, s_j}^E] \quad (26.3)$$

$$\frac{dk_{r_2, r_1}^E}{dt} = \epsilon(K.) [\alpha \cos(\varphi_{r_2} - \varphi_{r_1}) - k_{r_2, r_1}^E] \quad (27.3)$$

به طور مشابه برای اتصالات در حالت بازدارنده، قوانین زیر را داریم:

$$\frac{dk_{s_j, r_1}^I}{dt} = \epsilon(K.) [\alpha \cos(\varphi_{s_j} - \varphi_{r_1}) - k_{s_j, r_1}^I] \quad (28.3)$$

$$\frac{dk_{s_j, r_2}^I}{dt} = \epsilon(K.) [\alpha \cos(\varphi_{s_j} - \varphi_{r_2}) - k_{s_j, r_2}^I] \quad (29.3)$$

$$\frac{dk_{r_1, r_2}^I}{dt} = \epsilon(K.) [\alpha \cos(\varphi_{r_1} - \varphi_{r_2}) - k_{r_1, r_2}^I] \quad (30.3)$$

$$\frac{dk_{r_1, s_j}^I}{dt} = \epsilon(K.) [\alpha \cos(\varphi_{r_1} - \varphi_{s_j}) - k_{r_1, s_j}^I] \quad (31.3)$$

$$\frac{dk_{r_2, s_j}^I}{dt} = \epsilon(K.) [\alpha \cos(\varphi_{r_2} - \varphi_{s_j}) - k_{r_2, s_j}^I] \quad (32.3)$$

$$\frac{dk_{r_2, r_1}^I}{dt} = \epsilon(K.) [\alpha \cos(\varphi_{r_2} - \varphi_{r_1}) - k_{r_2, r_1}^I] \quad (33.3)$$

که در معادلات فوق، φ_{s_j} ، φ_{r_1} و φ_{r_2} فاز نوسانگرها و ω فرکانس طبیعی آن‌ها می‌باشند. همچنین K ضریب اتصال میان نوسانگر تقویت و نوسانگرهای محرک و پاسخ می‌باشد. این فرض علاوه بر معادلات کوراموتو به مسأله اضافه شده است. در مدل ارائه شده فرض شده که K از یک توزیع نرمال

با میانگین \bar{K} و انحراف معیار σ_K پیروی می‌کند و تابع چگالی آن برابر است با

$$f(K.) = \frac{1}{\sigma_K \sqrt{2\pi}} \exp\left\{-\frac{1}{2\sigma_K^2}(K. - \bar{K}.)^2\right\} \quad (34.3)$$

مقدار $\epsilon(K.)$ از رابطه زیر به دست می‌آید

$$\epsilon(K.) = \begin{cases} 0 & K. < K' \\ \epsilon. & \text{در غیر این صورت} \end{cases} \quad (35.3)$$

نام مدل	نوع شبکه	آگاهی از ذات مسأله	بخش یادگیرنده
MLP	شبکه عصبی	خیر	اتصالات سیناپسی
[۳]	مدل کوراموتو	بله	اتصالات سیناپسی
[۴]	مدل کوراموتو	خیر	اتصالات سیناپسی
[۵]	مدل کوراموتو	خیر	فرکانس طبیعی نوسانگرها
[۶]	مدل کوراموتو	بله	خصوصیات محلی و سراسری
[۷]	مدل کوراموتو	خیر	خصوصیات محلی و سراسری

جدول ۱۰۳: مقایسه و جمع‌بندی کارهای پیشین

که در آن $\alpha, \omega, \epsilon \ll 1$ و K در طول زمان مقداری ثابت است. K' هم یک آستانه ثابت در طول مراحل یادگیری است. تابع $\epsilon(K)$ نمایانگر تأثیرات غیرخطی در مغز است و به عنوان مثال می‌تواند با یک تابع سیگموید^{۴۲} مانند $\epsilon(K) = \frac{1}{1 + \exp\{\gamma(K - K')\}}$ جایگزین شود.

در نهایت در این مدل ارائه شده نظریه محرک-پاسخ توسط یک شبکه از نوسانگرهای فاز که رابطه میان آن‌ها از قوانین اختلاف فاز کوراموتو منتج شده بود، بررسی شد. با اعمال قوانین یادگیری مربوط به فاز نوسانگرها و ضرایب اتصال میان آن‌ها شبکه جدیدی ارائه شد. رفتار یک شبکه ارائه شده با سه نوسانگر با خصوصیات رفتاری مدل مستخرج از نظریه محرک-پاسخ مقایسه شد و شباهت قابل توجهی میان آن‌ها دیده شد. در نهایت کاربرد این مدل در روندهای روانشناختی و نظریه محرک-پاسخ بیان شده است.

۴.۳ مقایسه و جمع‌بندی

در این بخش با رسم یک جدول به مقایسه و جمع‌بندی مدل‌های پیشین می‌پردازیم. این مقایسه از چندین جهت صورت می‌گیرد. یکی از آن‌ها نوع یادگیری موجود در یک مدل اعم از اطلاع یا عدم اطلاع از ذات مسأله می‌باشد. یکی دیگر از معیارهای موجود برای یک مدل نوع یادگیری موجود در آن اعم از یادگیری اتصالات سیناپسی، یادگیری خصوصیات محلی نوسانگرها و یا یادگیری هر دوی این‌ها. یک خصوصیت دیگر که می‌توان آن را در مدل‌های مختلف با یکدیگر مقایسه کرد استفاده از مدل نوسانگرهای کوراموتو می‌باشد. همه این‌ها در جدول ۱۰۳ آمده است.

^{۴۲} sigmoid

فصل ۴

مدل بهبودیافته و نتایج پیاده‌سازی

در فصل‌های قبل با دانش موجود در همزمانی و شبکه نوسانگرهای فاز آشنا شدیم، همچنین به بررسی مدل‌های یادگیری ارائه شده پرداختیم. در این فصل با بیان مشکلات موجود در کارهای پیشین و سعی در بهبود آن‌ها به ارائه یک مدل یادگیری جدید در شبکه نوسانگرهای عصبی می‌پردازیم. برای مقایسه مدل ارائه شده جدید از حل چند مسأله شناسایی الگو استفاده می‌کنیم که نتایج پیاده‌سازی در بخش ۴.۳ آمده است.

۱.۴ مشکلات موجود در روش‌های پیشین

در این بخش به مقایسه و بررسی مشکلات موجود در روش‌های یادگیری پیشین می‌پردازیم. این مدل‌ها را از دیدگاه کاربردی می‌توان به دو دسته اصلی تقسیم کرد. دسته اول مدل‌هایی هستند که بدون این که از ذات یک مسأله شناسایی خبر داشته باشند به یادگیری می‌پردازند. مدل‌های مبتنی بر شبکه‌های عصبی همچنین مدل ارائه شده در [۵] از این دسته می‌باشند. دسته دوم مدل‌هایی هستند که با هدف به کار بردن مدل در یک حوزه خاص و در نهایت ارائه مدلی است که بالاترین همبستگی را با داده‌های واقعی تجربی در آن حوزه دارد. مدل‌های ارائه شده در [۶، ۳، ۴۳] از این دسته می‌باشند.

هدف ما در این پژوهش ارائه مدلی از دسته اول است، فلذا برای مقایسه به سراغ مدل‌هایی می‌رویم که بتوان آن‌ها را مستقل از جنس مسأله شناسایی بر روی آن اجرا کرد. مدل‌های مبتنی بر شبکه‌های عصبی مدل‌هایی به تنهایی کامل هستند و کارکرد آن‌ها را در بسیاری از حوزه‌ها در طول سالیان اخیر

مشاهده کرده‌ایم. فرض اساسی در این مدل‌ها این است که اجزاء تشکیل دهنده شبکه نوروها هستند. مشکل اصلی این مدل‌ها در دسترس نبودن اطلاعات و داده‌های واقعی از مغز در سطح نوروهاست، و به طور متقابل عدم توانایی انجام محاسبات یک شبکه عصبی مصنوعی در حد و اندازه واقعی مغز است. چراکه اگر بخواهیم به یادگیری یک شبکه عصبی مصنوعی با تعداد نوروها و سیناپس‌های برابر با مغز انسان بپردازیم (تقریباً حدود ۱۰ میلیارد نورو و ۶۰ هزار میلیارد سیناپس)، حتی با سریع‌ترین کامپیوترها فرآیند یادگیری سال‌ها و شاید قرن‌ها به طول بیانجامد. از این رو امروزه توجه به یادگیری در شبکه نوسانگرهای فاز بیشتر شده است. چون در این مدل یک نوسانگر که کوچکترین واحد محاسباتی است خود نماینده میلیون‌ها نورو است و در داده‌های زیستی واقعی مانند EEG، MEG و fMRI نمود پیدا می‌کنند. همچنین کارهای موجود در [۶، ۳، ۴۳، ۴۷] از این واقعیت خبر می‌دهند.

از این رو ما در این پژوهش به سراغ مدلی مبتنی بر نوسانگرهای فاز رفتیم. و از میان مدل‌های ارائه شده برای توصیف همزمانی مدل کوراموتو در شبکه‌های پیچیده را انتخاب کرده‌ایم. زیرا به دلیل داشتن نتایج بسیار خوب و قابل قبول در زمینه همزمانی به صورت همزمان مدلی ساده و قابل پیاده‌سازی می‌باشد. یکی از نکاتی که در کارهای قبلی به آن پرداخته نشده است، توجه به وزن اتصالات در مدل کوراموتو به منظور یادگیری است. در [۵] ادعا شده که در شبکه نوسانگرهای فاز تحت مدل کوراموتو، این فرکانس طبیعی نوسانگرها می‌باشد که از اهمیت بالایی برخوردار است و ضرایب اتصالات میان آن‌ها در نتایج به دست آمده تأثیر چندانی ندارد. اما از آن جایی که یک شبکه نوسانگرهای عصبی در واقع خلاصه شده یک شبکه عصبی متشکل از نوروها و سیناپس‌هاست که در آن وزن اتصالات سیناپسی بسیار مهم می‌باشد، تا آن جایی که می‌دانیم در یک شبکه عصبی پس از آموزش شبکه دانش ذخیره شده در شبکه در اتصالات سیناپسی آن ذخیره شده است. پس این فرض که از تمایز این اتصالات صرف‌نظر کرده و همه را یک اندازه بگیریم نمی‌تواند فرض کاملاً درستی باشد.

در نهایت بر آن شدیم تا مدل یادگیری جدیدی ارائه دهیم که در یک شبکه نوسانگرهای عصبی علاوه بر معادلات مربوط به یادگیری فاز نوسانگرها به یادگیری اتصالات سیناپسی نیز پرداخته شود. اصلی‌ترین رویکرد برای بررسی توانایی مدل یادگیری جدید، رویکرد شناسایی الگو است که در بخش ۳.۴ به بررسی نتایج مربوط به آن می‌پردازیم.

۲.۴ مدل ارائه شده

در این بخش به بیان دقیق مدل پیشنهادی و معادلات مربوط به آن می‌پردازیم. مفهوم اساسی که از آن در این جا بهره می‌گیریم، استفاده از مدل محرک-پاسخ است. در این راستا نوسانگرهای یک شبکه را به دو دسته محرک^۱ و پاسخ^۲ تقسیم می‌کنیم. در این مفهوم، نوسانگرهای محرک در واقع نماینده یک تحریک عصبی خارجی می‌باشند که به مغز وارد شده و نوسانگرهای پاسخ نماینده تحریک عصبی نورون‌های بخش پاسخ به محرک مغز هستند. در این روش همزمانی نوسانگرها نماینده داده پردازش شده در مغز است که متناظر با نوع الگوی بدست آمده از همزمانی نوسانگرها است و چگونگی آن نوع معادلات یادگیری مربوط به شبکه می‌باشد.

یک شبکه متشکل از $N + M$ نوسانگر در نظر بگیرید. دسته اول نوسانگرهای محرک

$$S = \{s_1, s_2, \dots, s_N\} \quad (۱.۴)$$

و دسته دوم نوسانگرهای پاسخ

$$R = \{r_1, r_2, \dots, r_M\} \quad (۲.۴)$$

می‌باشند. هر نوسانگر را با فرض این که می‌توانیم آن را به صورت کمی نشان دهیم با یک معادله همانند $x_n(t) = A_n(t) \cos \phi_n(t)$ قابل نمایش است که در آن کمیت نوسانگر n -ام در زمان t نشان داده شده است. $A_n(t)$ و $\phi_n(t)$ نیز به ترتیب دامنه و فاز نوسانگر می‌باشند. ارتباط میان نوسانگرهای شبکه در طول زمان از معادلات زیر به دست می‌آید:

- پیروی از مدل کوراموتو^۳ برای نوسانگرهای محرک، برای $1 \leq i \leq N$ داریم:

$$\frac{d\phi_i^S}{dt} = f_i^S + \sum_{j=1}^M A_i^S A_j^R k_{ij} \sin[\phi_j^R(t) - \phi_i^S(t)] \quad (۳.۴)$$

و برای نوسانگرهای پاسخ، برای $1 \leq j \leq M$ داریم:

$$\frac{d\phi_j^R}{dt} = f_j^R + \sum_{i=1}^N A_i^S A_j^R k_{ij} \sin[\phi_i^S(t) - \phi_j^R(t)] + \sum_{l=1}^M A_j^R A_l^R q_{lj} \sin[\phi_l^R(t) - \phi_j^R(t)] \quad (۴.۴)$$

^۱stimulus

^۲response

^۳kuramoto

نام متغیر	توضیح متغیر
S	مجموعه نوسانگرهای محرک
R	مجموعه نوسانگرهای پاسخ
N	تعداد نوسانگرهای محرک
M	تعداد نوسانگرهای پاسخ
ϕ_i^S	فاز نوسانگر محرک i -ام
ϕ_j^R	فاز نوسانگر پاسخ j -ام
A_i^S	دامنه نوسانگر محرک i -ام
A_j^R	دامنه نوسانگر پاسخ j -ام
f_i^S	فرکانس طبیعی نوسانگر محرک i -ام
f_j^R	فرکانس طبیعی نوسانگر پاسخ j -ام
k_{ij}	ضریب اتصال میان نوسانگر محرک i -ام و نوسانگر پاسخ j -ام
q_{ij}	ضریب اتصال میان نوسانگرهای پاسخ i -ام و j -ام
μ_{ij}, α, β	پارامترهای یادگیری

جدول ۱۰.۴: لیست متغیرهای موجود در مدل پیشنهادی

- یادگیری تقویتی فرکانس طبیعی نوسانگرهای پاسخ، برای $1 \leq j \leq M$ داریم:

$$\frac{df_j^R}{dt} = \sum_{l=1}^M \mu_{lj} \left(\frac{d\phi_l^R(t)}{dt} - f_j^R(t) \right) \quad (5.4)$$

- یادگیری تقویتی وزن اتصالات سیناپسی میان نوسانگرهای محرک و نوسانگرهای پاسخ، برای

$1 \leq j \leq M$ و $1 \leq i \leq N$ داریم:


$$\frac{dk_{ij}}{dt} = \alpha \cos(\phi_j^R(t) - \phi_i^S(t)) + \beta k_{ij} \quad (6.4)$$

- و برای اتصالات سیناپسی میان دو نوسانگر پاسخ، برای $1 \leq i, j \leq M$ داریم:

$$\frac{dq_{ij}}{dt} = \alpha \mu_{ij} \sin(\phi_j^R(t) - \phi_i^R(t)) + \beta q_{ij} \quad (7.4)$$

که در آن مقدار هر کدام از متغیرها در جدول ۱۰.۴ آمده است.

در توضیح روابط فوق ابتدا ملاحظه می‌کنیم که با توجه به معادلات ۳.۴ و ۴.۴، نحوه اتصال و برقراری ارتباط میان نوسانگرها پیرو مدل کوراموتو در شبکه‌های پیچیده (رابطه ۶.۲) است. با این تفاوت که نوسانگرهای محرک به یکدیگر متصل نیستند و اتصالات فقط میان نوسانگرهای محرک با



شکل ۱.۴: نحوه اتصال نوسانگرهای فاز در مدل ارائه شده، همان طور که در شکل دیده می‌شود نوسانگرها به دو دسته محرک و پاسخ تقسیم می‌شوند. اتصالات میان نوسانگرهای محرک و پاسخ و اتصالات میان نوسانگرهای پاسخ موجود هستند، ولی میان نوسانگرهای محرک اتصالی وجود ندارد.

نوسانگرهای پاسخ (با ضرایب اتصال k_{ij}) و میان نوسانگر پاسخ با همدیگر (با ضریب اتصال q_{ij}) می‌باشند. نمای کلی این شبکه در شکل ۱.۴ آمده است.

برای توضیح رابطه ۵.۴ ابتدا باید مفهوم فرکانس لحظه‌ای^۴ توضیح داده شود. به مشتق فاز یک نوسانگر که بیانگر تغییرات فاز آن است فرکانس لحظه‌ای گفته می‌شود:

$$\omega_i = \frac{d\phi_i}{dt} \quad (۸.۴)$$

لازم به ذکر است که در این جا هر دو f_i و ω_i فرکانس می‌باشند. منتها f_i که فرکانس طبیعی یک نوسانگر است و در روابط ۳.۴، ۴.۴ و ۵.۴ وارد می‌شود بر حسب هرتز است. ولی ω_i که در رابطه ۴.۵ وارد می‌شود بر حسب رادیان بر ثانیه است.

رابطه ۵.۴ بیانگر یک مدل یادگیری تقویتی برای فرکانس طبیعی نوسانگرهای پاسخ می‌باشد. رابطه مذکور بیانگر این امر است که اگر دو نوسانگر قرار است که با یکدیگر همزمان بشوند و فرکانس طبیعی یکی از آنها با فرکانس لحظه‌ای دیگری فاصله دارد، فرکانس طبیعی نوسانگر اول به سمت فرکانس لحظه‌ای دومی تقویت می‌شود و بالعکس. ضرایب $\mu_{ij} = \mu_{ji}$ پارامترهای یادگیری هستند و به گونه‌ای

^۴instantaneous frequency

انتخاب می‌شوند که اگر قرار است دو نوسانگر i و j همزمان بشوند $\mu_{ij} > 0$ ، اگر قرار است که همزمان نشوند $\mu_{ij} < 0$ و اگر همزمانی دو نوسانگر برای ما اهمیتی ندارد $\mu_{ij} = 0$ خواهد بود.

روابط ۶.۴ و ۷.۴ یک یادگیری تقویتی برای وزن اتصالات شبکه می‌باشند. در این روابط پارامترهای یادگیری α و β دارای قدرمطلق بسیار کم هستند ($|\alpha|, |\beta| \ll 1$) که در برخی موارد می‌توانند حتی صفر در نظر گرفته شوند. رابطه ۶.۴ بیانگر این است که اگر نوسانگر محرک i و نوسانگر پاسخ j فاز نزدیک به هم دارند ضریب اتصال میان آن‌ها تقویت می‌شود. رابطه ۷.۴ به این معنی است که اگر دو نوسانگر دارای فازهای غیرهمزمان هستند و با توجه به μ_{ij} باید فاز نزدیک به هم داشته باشند، رابطه میان آن‌ها تقویت می‌شود.

۳.۴ شناسایی الگو

در این بخش ابتدا به نحوه آموزش و یادگیری مدل مطرح شده به هدف شناسایی الگو می‌پردازیم. سپس آن را بر روی چند مسئله شناسایی الگو اجرا می‌کنیم. ابتدا باید توجه کرد که نوع مسأله‌ای که در این جا به آن پرداخته می‌شود یک مسئله دسته‌بندی^۵ است. به این صورت که داده‌های آموزش^۶ ما عبارت‌اند از:

$$(x_1, c_1), (x_2, c_2), \dots, (x_P, c_P) \quad (9.4)$$

$$\forall 1 \leq i \leq P : x_i \in \mathbb{C}^N, c_i \in \{1, 2, \dots, C\} \quad (10.4)$$

که در آن x_i بردار خصوصیات داده آموزش i -ام و c_i کلاسی است که این داده به آن تعلق دارد. N تعداد خصوصیت‌ها، C تعداد کلاس‌های موجود در مسئله و P تعداد داده‌های آموزش می‌باشد. داده‌های آزمون^۷ عبارتند از:

$$(y_1, d_1), (y_2, d_2), \dots, (y_Q, d_Q) \quad (11.4)$$

$$\forall 1 \leq i \leq Q : y_i \in \mathbb{C}^N, d_i \in \{1, 2, \dots, C\} \quad (12.4)$$

که در آن Q تعداد داده‌های آزمون است. y_i بردارهای داده‌های آزمون و d_i کلاس مربوط به هر کدام از آن‌هاست. هدف پیدا کردن کلاس مربوط به هر کدام از y_i با بیشترین دقت ممکن است.

^۵classification

^۶train data

^۷test data

مراحل الگوریتم یادگیری به ترتیب زیر می باشد:

۱. پارامترهای مسأله: مشخصات مجموعه محرک، تعداد نوسانگرهای محرک (N) و مشخصات

$$s_i = (A_i^S, f_i^S, \phi_i^S(\cdot))$$

مشخصات مجموعه پاسخ، تعداد نوسانگرهای پاسخ (M) و مشخصات آنها ($r_j = (A_j^R, f_j^R, \phi_j^R(\cdot))$)

وزن اتصالات شبکه،

$$k_{ij}, 1 \leq i \leq N, 1 \leq j \leq M \quad (13.4)$$

$$q_{jl}, 1 \leq j, l \leq M \quad (14.4)$$

پارامترهای یادگیری، مقادیر μ_+ ، μ_- ، β ، α که داریم:

$$\mu_{ij} = \begin{cases} \mu_+ & \text{نوسانگرهای } i \text{ و } j \text{ باید همزمان بشوند} \\ \mu_- & \text{نوسانگرهای } i \text{ و } j \text{ نباید همزمان بشوند} \\ 0 & \text{همزمانی نوسانگرهای } i \text{ و } j \text{ بی اهمیت است} \end{cases} \quad (15.4)$$

مقدار T که تعداد مراحل زمانی است. یعنی تمام معدلات شبکه در $1 \leq t \leq T$ اجرا می شوند.

۲. شرایط اولیه: تعداد نوسانگرهای محرک برابر با تعداد ابعاد داده های آموزش و آزمون خواهد بود

(N). همچنین داریم

$$A_i^S = |x_i| \quad (16.4)$$

$$\phi_i^S(\cdot) = \arg\{x_i\} \quad (17.4)$$

فاز بقیه نوسانگرها به طور تصادفی از بازه $[0, 2\pi]$ انتخاب می شود. همچنین فرکانس طبیعی آنها

نیز به طور تصادفی از بازه $[5, 45]$ هرتر انتخاب می شود، چرا که مشاهده شده است که فرکانس های

فعالیت های شناختی صورت گرفته در مغز نیز در همین محدوده می باشد.

۳. دینامیک مدل: رابطه میان نوسانگرها و قوانین یادگیری فرکانس های طبیعی آنها و ضرایب

اتصالات سیناپسی از روابط ۳.۴، ۴.۴، ۵.۴، ۶.۴ و ۷.۴ پیروی می کنند.

۴. استخراج الگوهای داده های آموزش: پس از اجرای مراحل و اتمام زمان شبیه سازی، الگوهای به

وجود آمده محاسبه می شوند. به این صورت که برای هر ورودی از داده های آموزش مانند x_i ، یک

ماتریس $R \times R$ به نام W_i ساخته می‌شود که درایه‌های آن از رابطه زیر به دست می‌آیند:

$$W_i = \{w_{jl}^i\}_{R \times R} \quad (18.4)$$

$$\forall 1 \leq j, l \leq M : w_{jl}^i = \begin{cases} 0 & \text{Var}[\sin(\phi_j^R - \phi_l^R)] \geq \epsilon \\ 1 & \text{Var}[\sin(\phi_j^R - \phi_l^R)] < \epsilon \end{cases} \quad (19.4)$$

که مقدار ϵ قبل از شبیه‌سازی تعیین می‌شود. همان‌طور که دیده می‌شود برای همزمانی از تعریف شبه-همزمانی که در ۱۵.۲ بیان شده بود استفاده کردیم.

۵. روش انتخاب μ_{ij} در هر گام: برای $i = 2, \dots, P$ ، الگوی W_i متناظر با x_i را به دست آورده، مقدار پارامتر $\mu_{jl} = \mu_+$ قرار می‌دهیم اگر نوسانگرهای j و l در الگوی W_{i-1} همزمان هستند ولی در W_i همزمان نیستند. همین‌طور مقدار پارامتر را $\mu_{jl} = \mu_-$ قرار می‌دهیم اگر نوسانگرهای j و l در الگوی W_{i-1} همزمانی نباشند ولی در الگوی W_i همزمان باشند. در غیر این صورت $\mu_{jl} = 0$ قرار می‌دهیم.

۶. استخراج الگوهای داده‌های آزمون: داده‌های آزمون (y_1, y_2, \dots, y_Q) را به عنوان ورودی به شبکه می‌دهیم و الگوهای مربوط به هر کدام از آن‌ها را همانند مرحله ۴ به دست می‌آیند. با این تفاوت که پارامترهای یادگیری یعنی فرکانس طبیعی نوسانگرهای پاسخ و وزن اتصالات دیگر تغییر نمی‌کنند. این الگوها را در ماتریس‌های $R \times R$ به نام V_1, V_2, \dots, V_Q ذخیره می‌کنیم.

۷. مرحله نهایی: الگوهای به دست آمده V_1, V_2, \dots, V_Q را به صورت دو به دو با الگوهای به دست آمده از داده‌های آموزش یعنی W_1, W_2, \dots, W_P مقایسه می‌کنیم. روش مقایسه فاصله همینگ^۸ دو ماتریس خواهد بود. بعد از آن برای هر i و برای هر کلاس از ۱ تا C ، میانگین فاصله‌های همینگ V_i تا آن W_j ‌هایی که متعلق به آن کلاس هستند محاسبه می‌شود و کلاسی که کمترین مقدار (فاصله) را با V_i دارد به عنوان کلاس داده آزمون y_i شناسایی می‌شود. درصد شناسایی‌های درست را نرخ شناسایی می‌نامیم.

^۸hamming

۱.۳.۴ مقاومت نسبت به نویز

همان طور که می دانیم اغلب داده های زیست داده ورزی^۹ دارای نویز بسیار می باشند. از این رو یک مسأله خیلی مهم مربوط به مدل ها و الگوریتم هایی که در این عرصه وجود دارند، مقاومت آن ها نسبت به نویز^{۱۰} می باشد. به عنوان مثال داده های EEG که یکی از مبنای اصلی استفاده از شبکه های نوسانگر فاز در یادگیری های مربوط به مغز می باشد، دارای نویز بسیار فراوانی می باشد. در این بخش نشان می دهیم که مدل ارائه شده این خاصیت را دارد و نسبت به نویز مقاوم است.

برای این کار کافی است که به فرکانس طبیعی نوسانگرهای محرک یک عامل تصادفی اضافه کنیم. به این صورت که اگر $f_i^S(t)$ فرکانس طبیعی نوسانگر محرک i -ام باشد، به جای آن $f_i^S(t) + \rho_i(t)$ قرار می دهیم که در آن $\rho_i(t)$ یک نویز سفید گاوسی با میانگین صفر^{۱۱} می باشد. بعد از اضافه کردن نویز به فرکانس طبیعی نوسانگرهای محرک، الگوهای همزمانی به دست آمده را با الگوهای همزمانی به دست آمده برای حالت بدون نویز مقایسه می کنیم. درصد تطبیق این الگوهای به دست آمده مقاومت مدل را نسبت به نویز نشان می دهد.

فرض کنید که H مجموعه محرک مستقل S_1, S_2, \dots, S_H با حالت های اولیه دلخواه در دست باشند. به طوری که

$$\forall 1 \leq i \leq H : S_i = \{(A_j^{S(i)}, \phi_j^{S(i)}(\cdot), f_j^{S(i)})\}_{j=1, \dots, N} \quad (20.4)$$

مجموعه محرک نویزی جدید S'_1, S'_2, \dots, S'_H را به این صورت تعریف می کنیم:

$$\forall 1 \leq i \leq H : S'_i = \{(A_j^{S(i)}, \phi_j^{S(i)}(\cdot), f_j^{S(i)} + \rho_j^i(t))\}_{j=1, \dots, N} \quad (21.4)$$

و پس از اجرای الگوریتم یادگیری که در ۳.۴ توضیح داده شد، نتایج مجموعه محرک جدید را با نتایج مجموعه محرک اولیه مقایسه می کنیم. به بیان دیگر برای حالت نویزی دقیقاً همان شبکه اول را با تمامی مقادیر اولیه یکسان اجرا می کنیم با این تفاوت که معادله ۳.۴ به معادله زیر تغییر پیدا می کند:

$$\frac{d\phi_i^S}{dt} = f_i^S + \rho_i(t) + \sum_{j=1}^M A_i^S A_j^R k_{ij} \sin[\phi_j^R(t) - \phi_i^S(t)] \quad (22.4)$$

نتایج این بخش در شکل ۲.۴ آمده است. در این آزمایش مقدار $H = 10$ قرار داده شد. همچنین تعداد نوسانگرهای محرک متغیر و برای ۵، ۱۰ و ۲۰ تعداد نوسانگر تکرار شده است. به همین ترتیب تعداد

^۹bioinformatics

^{۱۰}noise robustness

^{۱۱}zero mean Gaussian white noise

نوسانگرهای پاسخ نیز متغیر و از ۱۰ تا ۵۰ با افزایش ۵ تایی بوده است. مقادیر اولیه فرکانس طبیعی به صورت تصادفی از بازه [۵, ۴۵] انتخاب شده‌اند (دلیل این انتخاب در بخش پیشین توضیح داده شده است). مقادیر اولیه k_{ij} ، یعنی اتصالات سیناپسی میان نوسانگرهای محرک و پاسخ به صورت یکنواخت از بازه [۰, ۲] و مقادیر اولیه q_{ij} ، یعنی اتصالات سیناپسی میان نوسانگرهای پاسخ به صورت یکنواخت از بازه [۰, ۰/۵] انتخاب شده‌اند. چراکه به وضوح تأثیر اتصالات سیناپسی میان نوسانگرهای محرک و پاسخ باید بیشتر از همه باشد. مقدار $\rho_i(t)$ برابر با نویز گاوسی با میانگین صفر و انحراف معیار ۱۰ گرفته شده است. برای مقادیر پارامترهای یادگیری، مقدار μ_{ij} از روابط زیر به دست می‌آید:

$$\mu_+^1 = 5 \quad (23.4)$$

$$\mu_+^{i+1} = \frac{\mu_+^i}{(i+1)} \quad (24.4)$$

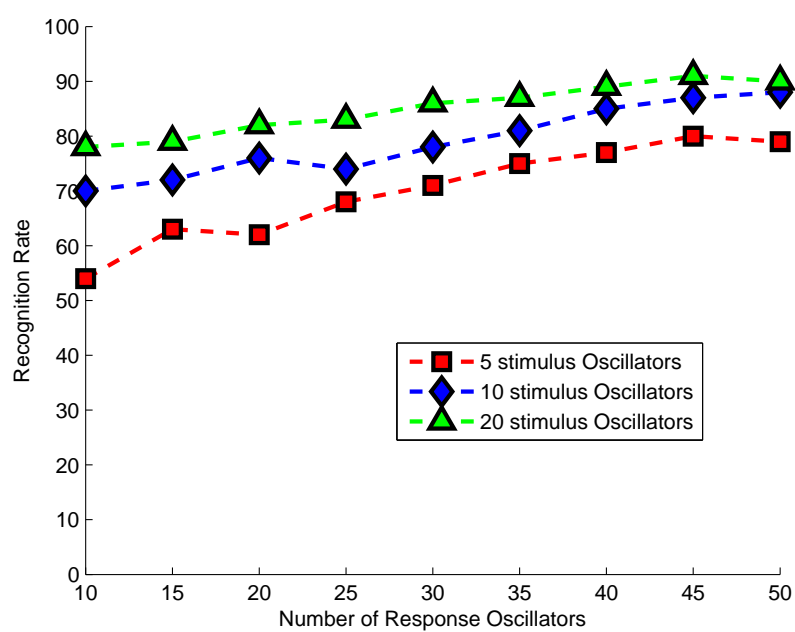
$$\mu_- = \frac{\mu_+}{2} \quad (25.4)$$

که در آن اندیس i نمایانگر مرحله یادگیری مربوطه (یا همان زمان) می‌باشد. دلیل این که مقدار μ در هر مرحله زمانی متفاوت از قبل گرفته شده است تأثیر بهتر این مقادیر از مقادیر ثابت است. توجه داشته باشید که انتخاب مقدار μ تأثیر بسیار زیادی بر روی الگوهای به دست آمده دارد، اغلب با تغییر مقدار μ ، مقدار جدید یا آنقدر زیاد است که فرکانس‌های مربوطه را بدون توجه به الگوهای مورد نظر یکی می‌کند یا آنقدر کم است که رابطه ۵.۴ بی‌تأثیر می‌شود. پارامترهای $\alpha = 0.3$ و $\beta = -0.3$ در نظر گرفته شده‌اند. مقادیر α و β همان طور که در بخش قبل توضیح داده شد باید اندازه کمتر از ۱ داشته باشند. α قدرت نزدیک شدن دو نوسانگر با فاز نزدیک به هم است و β باعث می‌شود که کوچک‌تر شدن وزن‌های ضعیف میان نوسانگرهای غیرهمزمان تقویت شود. زمان شبیه‌سازی $T = 500ms$ در نظر گرفته شده است.

نکته جالب درباره این آزمایش این است که با وجود این که نویز گاوسی با انحراف معیار ۱۰ برای شرایطی که فازهای نوسانگرها به طور تصادفی از بازه [۵, ۴۵] انتخاب می‌شوند، نویز بسیار زیاد و قابل توجهی است، با این حال نتایج به دست آمده خیلی شگفت‌آور است. این دستاورد باعث می‌شود تا بتوان از این مدل در مسائل نویزی بیوانفورماتیک استفاده کرد.

۲.۳.۴ شناسایی تصویر نویزی

در این بخش به حل یک مسئله شناسایی الگو می‌پردازیم. این مسئله شناسایی یک تصویر از نسخه نویزی آن است. علت انتخاب این مسئله علاوه بر نشان دادن تأثیر مدل ارائه شده برای حل مسائل شناسایی الگو،



شکل ۲.۴: نمودار درصد شناسایی صحیح الگوهای پاسخ برای مجموعه محرک نویزی، بر حسب تغییرات تعداد نوسانگرهای پاسخ. این نمودار برای تعداد نوسانگرهای محرک مختلف (۵، ۱۰ و ۲۰) رسم شده است.

2 1 0

(ج)

(ب)

(آ)

شکل ۳.۴: ارقام ۰، ۱ و ۲ با تعداد 107×80 پیکسل که هر رقم توسط یک دنباله به طول ۸۵۶۰ قابل نمایش است.

نشان دادن قدرت حذف نویز در آن و در واقع مقاومت این مدل نسبت به نویز می‌باشد. علت دیگر انتخاب این مسأله مطرح شدن آن در مدل یادگیری‌ای است که پیش از این ارائه شده [۵]. این کار که در بخش ۲.۳ مرور شده، بدون تغییر وزن اتصالات سیناپسی تنها به یادگیری فرکانس طبیعی نوسانگرها می‌پردازد. در این بخش با مقایسه نتایج این کار و مدل ارائه شده در این مقاله، بهبود آشکار درصد شناسایی را برای حل مسأله شناسایی تصویر خواهیم دید.


الگوهای مورد استفاده در این مدل در شکل ۳.۴ نشان داده شده‌اند. روش کار به این صورت می‌باشد که ابتدا مراحل یادگیری مدل را برای داده‌های آموزش که در واقع همان نسخه‌های بدون نویز تصاویر هستند، انجام می‌دهیم. سپس الگوهای به دست آمده از داده‌های تست که همان نسخه‌های نویزی تصاویر هستند را با معیار فاصله همینگ با الگوهای اولیه مقایسه می‌کنیم و نزدیک‌ترین الگو را به آن نسبت می‌دهیم. درصد الگوهای درست نسبت داده شده نرخ شناسایی می‌باشد.

برای حل این مسأله از یک شبکه با ۱۰ نوسانگر محرک و ۲۰ نوسانگر پاسخ استفاده می‌کنیم. مراحل الگوریتم استفاده شده در این بخش به صورت زیر می‌باشد:

۱. هر کدام از تصاویر را به صورت دنباله‌ای از پیکسل‌های سیاه و سفید نمایش می‌دهیم. به این صورت که چون ابعاد هر تصویر 107×80 است، می‌توان آن را به صورت یک دنباله به طول ۸۵۶۰ از ۰ و ۱ (نمایانگر سفید و سیاه) نمایش داد.

۲. تبدیل فوریه گسسته را برای هر کدام از دنباله‌ها به دست می‌آوریم.

۳. از میان ضرایب تبدیل فوریه، ۱۰ ضریب بزرگتر را برای هر تصویر انتخاب می‌کنیم. پس تا این جا به ازای هر تصویر (مستقل از نویزی و غیرنویزی بودن آن) یک دنباله به طول ۱۰ از اعداد مختلط داریم.



شکل ۴.۴: مقایسه درصد شناسایی صحیح رقم‌های نویزی بر حسب نسبت سیگنال به نویز تصویر در سه مدل مختلف،
 ۱- شبکه نوسانگرهای عصبی متشکل از ۳۰ نوسانگر فاز که با الگوریتم‌های یادگیری ارائه شده آموزش دیده‌اند.
 ۲- شبکه نوسانگرهای عصبی ارائه شده در [۵] و ۳- یک شبکه عصبی متشکل از ۲۰ نورون لایه پنهان

۴. دنباله‌های به دست آمده برای تصاویر بدون نویز را مجموعه آموزش و دنباله‌های به دست آمده برای تصاویر نویزی را مجموعه آزمون در نظر می‌گیریم. (مربوط به روابط ۹.۴ و ۱۱.۴)

۵. مطابق الگوریتم ارائه شده در بخش ۴، شبکه را اجرا و نرخ شناسایی را به دست می‌آوریم.

نتایج این آزمایش در نمودار شکل ۴.۴ قابل مشاهده است. در این نمودار درصد شناسایی صحیح به صورت تابعی از نویز اعمال شده به تصاویر رسم شده است. همچنین نتایج مدل ارائه شده در [۵] و نتایج شناسایی یک شبکه عصبی با ۳۰ نورون را نیز در این نمودار آورده‌ایم. همان طور که مشاهده می‌شود، مدل ارائه شده به خوبی قادر به شناسایی تصاویر می‌باشد و نتایج آن کاملاً بهتر از دو روش دیگر است. یک نکته جالب توجه در این مثال توانایی تشخیص بالای تصاویر نویزی توسط مدل ارائه شده است. به عنوان مثال تصویری که در آن نسبت سیگنال به نویز برابر با -10 dB باشد توسط این مدل حدود ۸۰ درصد مواقع درست تشخیص داده شده است در حالی که شناسایی این تصویر با چشم به سختی قابل انجام است. (شکل ۵.۴)



(ب) تصویر رقم صفر با $SNR = -10\text{ dB}$



(آ) تصویر رقم صفر با $SNR = -20\text{ dB}$



(د) تصویر رقم صفر با $SNR = 0\text{ dB}$



(ج) تصویر رقم صفر با $SNR = -5\text{ dB}$

شکل ۵.۴: تصاویر نویزی رقم صفر

نام خصوصیت	مینیمم	ماکزیمم	میانگین	هم‌بستگی درون کلاسی
طول کاسبرگ	۴.۳	۷.۹	۵.۸۴	۰.۷۸۲۶
عرض کاسبرگ	۲.۰	۴.۴	۳.۰۵	-۰.۴۱۹۴
طول گلبرگ	۱.۰	۶.۹	۳.۷۶	۰.۹۴۹۰
عرض گلبرگ	۰.۱	۲.۵	۱.۲۰	۰.۹۵۶۵

جدول ۲.۴: مشخصات آماری خصوصیت‌های مجموعه داده Iris

۳.۳.۴ سایر مسائل شناسایی الگو

در ادامه برای نشان دادن توانایی شناسایی الگو توسط مدل ارائه شده، آن را بر روی دو مجموعه داده معروف در این زمینه اجرا می‌کنیم. این مجموعه داده‌ها که به ترتیب Iris و Cars نام دارند، از انبار یادگیری ماشین دانشگاه ایرواین [۶۰] انتخاب شده‌اند. در این بخش نتایج شناسایی الگو را برای این دو مسئله دسته‌بندی می‌آوریم و آن را با مدل ارائه شده در [۵] مقایسه خواهیم کرد.

مجموعه داده Iris

مجموعه داده Iris توسط R.A.Fisher به وجود آمده است. این مجموعه داده در واقع معروف‌ترین مجموعه داده موجود در زمینه شناسایی الگو می‌باشد. داده‌های Iris از ۳ کلاس تشکیل شده‌اند که از هر کدام از کلاس‌ها ۵۰ داده وجود دارد. این کلاس‌های مختلف به سه نوع متفاوت گل زنبق اشاره دارند. هر کدام از داده دارای چهار خصوصیت^{۱۲} می‌باشد که به ترتیب طول کاسبرگ^{۱۳}، عرض کاسبرگ^{۱۴}، طول گلبرگ^{۱۵} و عرض گلبرگ^{۱۶} می‌باشند. اطلاعات خصوصیت‌ها و تحلیل آماری آن‌ها در جدول ۴.۲ مشاهده می‌شود.

برای حل مسئله دسته‌بندی ۷۰ درصد داده‌های هر کلاس را برای آموزش و ۳۰ درصد باقیمانده را برای آزمون در نظر گرفته‌ایم. همچنین تعداد نوسانگرهای پاسخ را متغیر از ۵ تا ۲۰ نوسانگر در نظر گرفتیم. درضمن هر آزمایش را ۵۰ بار برای مقادیر اولیه مختلف اجرا کرده و میانگین نتایج به دست آمده را به


^{۱۲}attribute

^{۱۳}sepal length

^{۱۴}sepal width

^{۱۵}petal length

^{۱۶}petal width



شکل ۶.۴: مقایسه نتایج شناسایی مجموعه داده *Iris* به دست آمده از مدل ارائه و [۵]، بر حسب تعداد نوسانگرهای پاسخ

عنوان نرخ شناسایی در نظر گرفتیم. نتایج این آزمایش در نمودار شکل آمده است. همان طور که مشاهده می شود نتایج مدل پیشنهادی در این مقاله از مدل قبلی کاملاً بهتر است و برای شبکه‌ای با ۲۰ نوسانگر پاسخ توانسته‌ایم تا ۹۲ درصد نرخ شناسایی را برای داده‌های *Iris* بالا ببریم.

مجموعه داده Cars

مجموعه داده Cars توسط بوهانک^{۱۷} پدیده آمده است. داده‌های Cars دارای خصوصیات ماشین‌های مختلف و قابلیت پذیرش یک ماشین (وابسته به خصوصیاتش) می باشد و به علت اطلاعاتی که در خود نهفته دارد به خصوص می تواند برای اهداف کشف ساختار^{۱۸} و مقایسه‌های مربوط به ساخت و ساز^{۱۹} به کار رود. این مجموعه داده شامل شش خصوصیت است که نام و مقادیر آنها در جدول ۳.۴ مشاهده

^{۱۷}Marko Bohanec

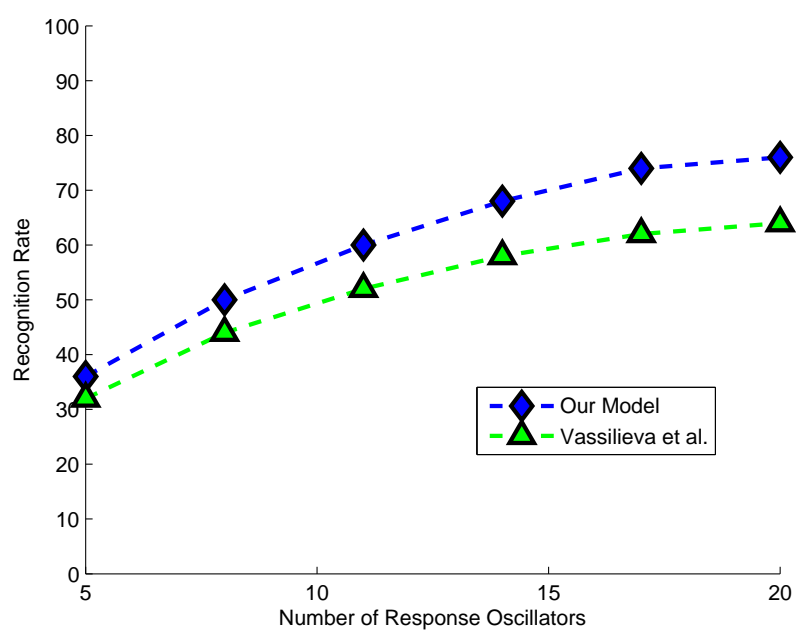
^{۱۸}structure discovery

^{۱۹}constructive induction

مقادیر هر خصوصیت				نام خصوصیت
خیلی زیاد	زیاد	متوسط	کم	قیمت خرید
خیلی زیاد	زیاد	متوسط	کم	هزینه نگهداری
۲	۳	۴	۵ یا بیشتر	تعداد درها
۲	۴	بیشتر		ظرفیت (نفر)
کم	متوسط	زیاد		گنجایش صندوق
کم	متوسط	زیاد		ایمنی

جدول ۳.۴: نام و مقادیر خصوصیت‌های مجموعه داده Cars

می‌شود. تعداد کلاس‌های موجود در این مجموعه داده ۴ تا است که شامل غیرقابل قبول، قابل قبول، خوب و خیلی خوب می‌باشند. برای حل مسأله دسته‌بندی از روی این داده‌ها ابتدا تعداد داده‌های هر کلاس را مساوی کردیم (با حذف تعدادی از داده‌ها). سپس مقادیر کیفی خصوصیت‌ها را با اعداد جایگزین کرده و آن‌ها را کمی کردیم. در آخر ۷۰ درصد از داده‌ها را برای آموزش و ۳۰ درصد آن‌ها را برای آزمون در نظر گرفتیم و نتایج آزمایش را با مدل قبلی مقایسه کردیم. این نتایج برحسب تغییر تعداد نوسانگرهای پاسخ در نمودار شکل ۷.۴ آمده‌اند. همان‌طور که ملاحظه می‌شود، در این مجموعه داده نیز نتایج به دست آمده از مدل پیشنهادی بهتر از نتایج مدل قبلی عمل می‌کند و برای شبکه پیشنهادی با ۲۰ نوسانگر پاسخ، نرخ شناسایی تا ۷۶ درصد رسیده است.




شکل ۷.۴: مقایسه نتایج شناسایی مجموعه داده *Cars* به دست آمده از مدل ارائه و [۵]، بر حسب تعداد نوسانگرهای پاسخ

فصل ۵

جمع‌بندی و پیشنهادهایی برای پژوهش‌های آینده

سالیان سال است که دانشمندان به دنبال ارائه روشی برای مدل‌سازی مصنوعی مغز انسان هستند. یک انقلاب عظیم در این زمینه کشف این حقیقت بود که مغز انسان از اجزای ریزتری به نام نورون‌ها و سیناپس‌های عصبی تشکیل شده است. بعد از این مدل‌هایی به نام شبکه‌های عصبی مصنوعی ارائه شد که تاکنون کارهای بی‌شماری با استفاده از این مدل‌ها انجام شده است. شبکه‌های عصبی مصنوعی سیستم‌های انطباقی می‌باشند که توانایی تخمین هر تابع دلخواهی را دارند و در مقیاس کوچک به خوبی شبیه‌سازی فعالیت مغز را دارند. مشکل اصلی در استفاده از این شبکه‌ها برای جایگزینی با مغز انسان، وجود تعداد بسیار زیاد نورون‌ها و سیناپس‌ها در مغز است. مغز انسان در حدود ۱۰ میلیارد نورون و ۶۰ هزار میلیارد سیناپس دارد. اگر بخواهیم یک شبکه عصبی مصنوعی با این تعداد نورون و سیناپس را آموزش دهیم، حتی با صرف نظر کردن از مشکلات حافظه، یادگیری این شبکه با قوی‌ترین کامپیوترهای موجود قرن‌ها به طول می‌انجامد!

اخیراً با پیشرفت دستگاه‌های ثبت امواج مغز، و دسترسی به اطلاعاتی همانند EEG (شکل ۲.۵)، MEG (شکل ۱.۵)، fMRI (شکل ۳.۵) و یا حتی ترکیبی از آن‌ها، بستر به وجود آمدن دیدگاه و رویکرد جدیدی برای مسأله مدل‌سازی مصنوعی مغز ایجاد شده است. به این صورت که دیگر با نورون‌های تنها سر و کار نداریم، بلکه با دسته‌هایی از نورون‌های کنار هم قرار گرفته مواجه هستیم که یک رفتار مشابه




شکل ۱.۵: منبع ایجاد میدان مغناطیسی در مغز، این جریان مغناطیسی (electric current) است که باعث ایجاد سیگنال‌های EEG و MEG می‌شود. تصویر فوق از کمپانی MedTech که تولید کننده CTF MEG می‌باشد، گرفته شده است.


به نمایش می‌گذارند. این رفتار به صورت سیگنال‌هایی متناوب و در حال نوسان می‌باشد. یکی از بهترین مدل‌های مطرح شده تاکنون برای توجیه این رفتار نوسانی، استفاده از یک شبکه نوسانگرهای فاز می‌باشد.

یک شبکه نوسانگرهای فاز علاوه بر مورد گفته شده، در بسیاری از مسائل ماکروسکوپیک جهان واقعی نیز کاربرد دارد. در واقع در مواردی که نیاز به توصیف پدیده همزمانی در یک شبکه دینامیکی یا یک شبکه پیچیده می‌باشد، یکی از بهترین گزینه‌ها استفاده از این شبکه است. از این رو مدل‌های مختلفی برای آن ارائه شده و بسیاری از کارهای انجام شده مربوط به آن به مثال‌های موجود در جهان واقعی مانند شبکه‌های اجتماعی برمی‌گردد. یکی از این مدل‌های مطرح شده مدل کوراموتو (۱.۲) می‌باشد. در این پژوهش برای مدل‌سازی روابط میان نوسانگرها از یک مدل کوراموتوی تغییر یافته استفاده کرده‌ایم.

اکثر کارهای پیشین که به مدل‌سازی مغز یا بخشی از آن پرداخته‌اند، سعی بر توجیه یک وظیفه از اعمال واقعی مغز انسان یا سایر موجودات داشته‌اند. از این دسته می‌توان به [۶۱، ۴۸، ۴۶، ۴۵، ۴۲، ۳۷، ۳۰، ۶۲، ۴۳، ۴۷] اشاره کرد که برخی از آن‌ها در بخش ۳ نیز مرور شده‌اند. در این پروژه ما به توجیه سیستماتیک رفتار مغز پرداختیم. برای این هدف مدلی ارائه شد که با استفاده از ویژگی‌های محلی و سراسری نوسانگرها به یادگیری دو مورد در شبکه بپردازد. اول به یادگیری فرکانس طبیعی نوسانگرها، و دوم با یک روش شبیه قانون یادگیری هب به یادگیری وزن اتصالات سیناپسی میان آن‌ها پرداختیم. علاوه



شکل ۲۰.۵: نمونه‌ای از یک سیگنال EEG ، سیگنال‌هایی که در شکل فوق مشاهده می‌شود تغییرات ولتاژ بر حسب زمان در طول ۱ ثانیه برای ۵ الکتروود از یک داده EEG گرفته شده از یک بیمار می‌باشد.



شکل ۳.۵: نمونه‌ای از یک داده fMRI اسکن شده، گرفته شده از *National Institute of Mental Health*.

بر این با دسته‌بندی نوسانگرهای شبکه به دو دسته محرک و پاسخ توانایی حل مسائل شناسایی الگو نیز توسط این مدل به نمایش درآمد. تاکنون هیچ کاری با رویکرد پیش‌بینی رفتار مغز چنین مدلی ارائه نکرده است.

برای بررسی توانایی مدل علاوه بر این امر که معماری مدل برگرفته از داده‌ها و حقایق زیست‌شناسی موجود است، به حل چند مسأله شناسایی الگو نیز پرداختیم. به این صورت که بعد از نشان دادن مقاومت بالای مدل نسبت به نویز، آن را بر روی سه مسأله دسته‌بندی که به ترتیب شناسایی تصویر نویزی، دسته‌بندی داده‌های Iris و دسته‌بندی داده‌های Cars بودند، اجرا کردیم. در آخر دیده شد که علاوه بر به دست آوردن نرخ شناسایی بسیار خوب در این مسائل، نتایج به دست آمده از مدل پیشین نیز بهتر بود.

یکی از نکات جالبی که می‌توان درباره این مدل به آن اشاره کرد، ظرفیت بالای شبکه برای نگهداری الگوهای متفاوت است که از آن تعبیر به حافظه شبکه می‌شود. در واقع حدسی که زده می‌شود این است که حافظه این مدل مطرح شده بسیار بالاتر از مدل‌های مشابه با تعداد اجزای مساوی است. برای مثال یکی از کارهای پیشین که می‌توان از آن نام برد شبکه هاپفیلد است. در این شبکه نشان داده شده است که حافظه‌ی یک شبکه متشکل از N نورون برابر با $N/(2 \log N)$ می‌باشد [۶۳]. در صورتی که در مثال‌هایی که به صورت تجربی از شبکه موجود زدیم، حافظه شبکه برای همان تعداد نوسانگر به مقدار قابل توجهی بیشتر از شبکه هاپفیلد بود. شاید یکی از کارهای مطرح در آینده روشی برای محاسبه دقیق

حافظه شبکه‌ای از نوسانگرهای عصبی تحت مدل ارائه شده باشد.

یکی دیگر از زمینه‌هایی که می‌توان این کار را در آن ادامه داد، اجرا کردن مدل ارائه شده بر روی داده‌های EEG یک وظیفه خاص است. امروزه EEG همچنان برای تشخیص و درمان برخی بیماری‌ها که مهم‌ترین آن‌ها صرع^۱ است استفاده می‌شود. با در دست داشتن اطلاعات کامل یک عمل شناختی و داده‌های EEG مربوط به آن، همچنین با استفاده از روش‌هایی که بخش‌های مختلف شناختی مغز را در اعمال متفاوت از هم تفکیک می‌کنند، می‌توان نوسانگرهای محرک و پاسخ را به صورت معنی‌داری از یکدیگر تمیز کرد. سپس با به کار بردن مدل ارائه شده بر روی شبکه حاصل می‌توان به شناخت رابطه میان نوسانگرهای محرک و پاسخ پرداخت. همچنین می‌توان امید داشت که این مطالعه بتواند به شناخت ساختار مغز و درمان بسیاری از نارسایی‌های حرکتی که ناشی از ناتوانی‌های مغزی می‌باشند، کمک کند.

^۱epilepsy

فصل ٦

مراجع

- [1] S. Haykin. *Neural Networks, A comprehensive foundation*. 2004.
- [2] G. Zhang, “Neural networks for classification: a survey,” *IEEE Transactions on Systems, Man, and Cybernetics, Part C: Applications and Reviews*, Vol.30, No.4, pp.451–462, 2000.
- [3] M. Trevisan, S. Bouzat, I. Samengo, and G. Mindlin, “Dynamics of learning in coupled oscillators tutored with delayed reinforcements,” *Physical Review E*, Vol.72, No.1, p.011907, 2005.
- [4] T. Aonishi, “Phase transitions of an oscillator neural network with a standard hebb learning rule,” *Physical Review E*, Vol.58, No.4, p.4865, 1998.
- [5] E. Vassilieva, G. Pinto, J. Acacio de Barros, and P. Suppes, “Learning pattern recognition through quasi-synchronization of phase oscillators,” *IEEE Transactions on Neural Networks*, Vol.22, No.1, pp.84–95, 2011.
- [6] H. Sompolinsky, D. Golomb, and D. Kleinfeld, “Global processing of visual stimuli in a neural network of coupled oscillators,” *Proceedings of the*

- National Academy of Sciences of the USA*, Vol.87, No.18, pp.7200–7204, 1990.
- [7] P. Suppes, J. de Barros, and G. Oas, “Phase-oscillator computations as neural models of stimulus–response conditioning and response selection,” *Journal of Mathematical Psychology*, Vol.56, No.1, pp.95–117, 2012.
 - [8] J. Bower and D. Beeman, “The book of genesis: Exploring realistic neural models with the general neural simulation system. internet edition, 2003,”
 - [9] W. Estes, “Toward a statistical theory of learning.,” *Psychological Review*, Vol.57, No.2, p.94, 1950.
 - [10] P. Suppes. *Stimulus sampling theory for a continuum of responses*. Stanford University, Institute for Mathematical Studies in the Social Sciences, Applied Mathematics and Statistics Laboratories, 1959.
 - [11] G. Shepherd and C. Koch, “Dendritic electrotonus and synaptic integration,” *The Synaptic Organization of the Brain*, pp.439–473, 1990.
 - [12] G. Cybenko, “Approximation by superpositions of a sigmoidal function,” *Mathematics of Control, Signals, and Systems*, Vol.2, No.4, pp.303–314, 1989.
 - [13] K. Hornik, “Approximation capabilities of multilayer feedforward networks,” *Neural Networks*, Vol.4, No.2, pp.251–257, 1991.
 - [14] K. Hornik, M. Stinchcombe, and H. White, “Multilayer feedforward networks are universal approximators,” *Neural Networks*, Vol.2, No.5, pp.359–366, 1989.
 - [15] B. Widrow, D. Rumelhart, and M. Lehr, “Neural networks: Applications in industry, business and science,” *Communications of the ACM*, Vol.37, No.3, pp.93–105, 1994.

- [16] E. Altman, G. Marco, and F. Varetto, "Corporate distress diagnosis: Comparisons using linear discriminant analysis and neural networks (the italian experience)," *Journal of Banking & Finance*, Vol.18, No.3, pp.505–529, 1994.
- [17] R. Lacher, P. Coats, S. Sharma, and L. Fant, "A neural network for classifying the financial health of a firm," *European Journal of Operational Research*, Vol.85, No.1, pp.53–65, 1995.
- [18] M. Leshno and Y. Spector, "Neural network prediction analysis: The bankruptcy case," *Neurocomputing*, Vol.10, No.2, pp.125–147, 1996.
- [19] K. Tam and M. Kiang, "Managerial applications of neural networks: the case of bank failure predictions," *Management Science*, Vol.38, No.7, pp.926–947, 1992.
- [20] R. Wilson and R. Sharda, "Bankruptcy prediction using neural networks," *Decision Support Systems*, Vol.11, No.5, pp.545–557, 1994.
- [21] G. Zhang, M. Y Hu, B. Eddy Patuwo, and D. C Indro, "Artificial neural networks in bankruptcy prediction: General framework and cross-validation analysis," *European Journal of Operational Research*, Vol.116, No.1, pp.16–32, 1999.
- [22] I. Guyon, "Applications of neural networks to character recognition," *International Journal of Pattern Recognition and Artificial Intelligence*, Vol.5, No.01n02, pp.353–382, 1991.
- [23] S. Knerr, L. Personnaz, and G. Dreyfus, "Handwritten digit recognition by neural networks with single-layer training," *IEEE Transactions on Neural Networks*, Vol.3, No.6, pp.962–968, 1992.

- [24] Y. Le Cun, B. Boser, J. Denker, D. Henderson, R. Howard, W. Hubbard, L. Jackel, *et al.*, “Handwritten digit recognition with a back-propagation network,” *ATT Bell Laboratories*, No.07733, 1990.
- [25] D. Lee, S. Srihari, and R. Gaborski. *Bayesian and neural network pattern recognition: a theoretical connection and empirical results with handwritten characters*. State University of New York at Buffalo, Department of Computer Science, 1990.
- [26] G. Martin and J. Pittman, “Recognizing hand-printed letters and digits using backpropagation learning,” *Neural Computation*, Vol.3, No.2, pp.258–267, 1991.
- [27] H. Bourlard and N. Morgan, “Continuous speech recognition by connectionist statistical methods,” *IEEE Transactions on Neural Networks*, Vol.4, No.6, pp.893–909, 1993.
- [28] R. Lippmann, “Review of neural networks for speech recognition,” *Neural Computation*, Vol.1, No.1, pp.1–38, 1989.
- [29] J. Hoskins, K. Kaliyur, and D. Himmelblau, “Incipient fault detection and diagnosis using artificial neural networks,” In *IJCNN International Joint Conference on*, pp.81–86, 1990.
- [30] W. Baxt, “Use of an artificial neural network for data analysis in clinical decision-making: the diagnosis of acute coronary occlusion,” *Neural Computation*, Vol.2, No.4, pp.480–489, 1990.
- [31] W. Baxt *et al.*, “Use of an artificial neural network for the diagnosis of myocardial infarction,” *Annals of Internal Medicine*, Vol.115, No.11, p.843, 1991.

- [32] H. Burke, "Artificial neural networks for cancer research: outcome prediction," In *Seminars in Surgical Oncology*, Vol.10, pp.73–79, Wiley Online Library, 2006.
- [33] H. Burke, P. Goodman, D. Rosen, D. Henson, J. Weinstein, F. Harrell, J. Marks, D. Winchester, and D. Bostwick, "Artificial neural networks improve the accuracy of cancer survival prediction," *Cancer*, Vol.79, No.4, pp.857–862, 2000.
- [34] S. Curram and J. Mingers, "Neural networks, decision tree induction and discriminant analysis: an empirical comparison," *Journal of the Operational Research Society*, pp.440–450, 1994.
- [35] E. Patuwo, M. Hu, and M. Hung, "Two-group classification using neural networks," *Decision Sciences*, Vol.24, No.4, pp.825–845, 2007.
- [36] V. Subramanian, M. Hung, and M. Hu, "An experimental evaluation of neural networks for classification," *Computers & Operations Research*, Vol.20, No.7, pp.769–782, 1993.
- [37] W. Freeman, "Nonlinear dynamics of paleocortex manifested in the olfactory eeg," *Biological Cybernetics*, Vol.35, No.1, pp.21–37, 1979.
- [38] W. Gerstner and W. Kistler. *Spiking neuron models: Single neurons, populations, plasticity*. Cambridge university press, 2002.
- [39] J. Wright and D. Liley, "Simulation of electrocortical waves," *Biological Cybernetics*, Vol.72, No.4, pp.347–356, 1995.
- [40] F. Hoppensteadt and E. Izhikevich, "Synaptic organizations and dynamical properties of weakly connected neural oscillators," *Biological Cybernetics*, Vol.75, No.2, pp.117–127, 1996.

- [41] E. Izhikevich. *Dynamical systems in neuroscience: the geometry of excitability and bursting*. MIT press, 2006.
- [42] R. Eckhorn, R. Bauer, W. Jordan, M. Brosch, W. Kruse, M. Munk, and H. Reitboeck, “Coherent oscillations: A mechanism of feature linking in the visual cortex?,” *Biological Cybernetics*, Vol.60, No.2, pp.121–130, 1988.
- [43] R. Friedrich, C. Habermann, and G. Laurent, “Multiplexing using synchrony in the zebrafish olfactory bulb,” *Nature Neuroscience*, Vol.7, No.8, pp.862–871, 2004.
- [44] V. Kazantsev, V. Nekorkin, V. Makarenko, and R. Llinas, “Self-referential phase reset based on inferior olive oscillator dynamics,” *Proceedings of the National Academy of Sciences of the USA*, Vol.101, No.52, pp.18183–18188, 2004.
- [45] A. Lutz, J. Lachaux, J. Martinerie, and F. Varela, “Guiding the study of brain dynamics by using first-person data: Synchrony patterns correlate with ongoing conscious states during a simple visual task,” *Proceedings of the National Academy of Sciences of the USA*, Vol.99, No.3, pp.1586–1591, 2002.
- [46] E. Leznik, V. Makarenko, and R. Llinás, “Electrotonically mediated oscillatory patterns in neuronal ensembles: an in vitro voltage-dependent dye-imaging study in the inferior olive,” *The Journal of Neuroscience*, Vol.22, No.7, pp.2804–2815, 2002.
- [47] V. Murthy and E. Fetz, “Coherent 25-to 35-hz oscillations in the sensorimotor cortex of awake behaving monkeys,” *Proceedings of the National Academy of Sciences of the USA*, Vol.89, No.12, pp.5670–5674, 1992.

- [48] W. Lytton and T. Sejnowski, “Simulations of cortical pyramidal neurons synchronized by inhibitory interneurons,” *Journal of Neurophysiology*, Vol.66, No.3, pp.1059–1079, 1991.
- [49] E. Park, P. So, E. Barreto, B. Gluckman, and S. Schiff, “Electric field modulation of synchronization in neuronal networks,” *Neurocomputing*, Vol.52, pp.169–175, 2003.
- [50] A. Winfree. *The geometry of biological time*, Vol.12. Springer Verlag, 2001.
- [51] J. Acebrón, L. Bonilla, C. Vicente, F. Ritort, and R. Spigler, “The kuramoto model: A simple paradigm for synchronization phenomena,” *Reviews of Modern Physics*, Vol.77, No.1, p.137, 2005.
- [52] M. Denker, M. Timme, M. Diesmann, F. Wolf, and T. Geisel, “Breaking synchrony by heterogeneity in complex networks,” *Physical Review Letters*, Vol.92, No.7, p.74103, 2004.
- [53] A. Arenas, A. Díaz-Guilera, J. Kurths, Y. Moreno, and C. Zhou, “Synchronization in complex networks,” *Physics Reports*, Vol.469, No.3, pp.93–153, 2008.
- [54] P. Gade, “Synchronization of oscillators with random nonlocal connectivity,” *Physical Review E*, Vol.54, No.1, p.64, 1996.
- [55] A. Batista, S. Pinto, R. Viana, and S. Lopes, “Mode locking in small-world networks of coupled circle maps,” *Physica A: Statistical Mechanics and its Applications*, Vol.322, pp.118–128, 2003.
- [56] M. Jalili, “Synchronization in dynamical networks: synchronizability, neural network models and eeg analysis,” *vol. PhD. Lausanne: EPFL*, 2008.

- [57] A. Arenas, A. Díaz-Guilera, and C. Pérez-Vicente, “Synchronization reveals topological scales in complex networks,” *Physical Review Letters*, Vol.96, No.11, p.114102, 2006.
- [58] A. Arenas, A. Diaz-Guilera, and C. Pérez-Vicente, “Synchronization processes in complex networks,” *Physica D: Nonlinear Phenomena*, Vol.224, No.1, pp.27–34, 2006.
- [59] A. Arenas and A. Diaz-Guilera, “Synchronization and modularity in complex networks,” *The European Physical Journal-Special Topics*, Vol.143, No.1, pp.19–25, 2007.
- [60] A. Frank and A. Asuncion, “UCI machine learning repository,” 2010.
- [61] O. David, K. Friston, *et al.*, “A neural mass model for meg/eeg:-coupling and neuronal dynamics,” *NeuroImage*, Vol.20, No.3, pp.1743–1755, 2003.
- [62] C. Gray, P. König, A. Engel, W. Singer, *et al.*, “Oscillatory responses in cat visual cortex exhibit inter-columnar synchronization which reflects global stimulus properties,” *Nature*, Vol.338, No.6213, pp.334–337, 1989.
- [63] R. McEliece, E. Posner, E. Rodemich, and S. Venkatesh, “The capacity of the hopfield associative memory,” *IEEE Transactions on Information Theory*, Vol.33, No.4, pp.461–482, 1987.
- [64] P. Baldi and R. Meir, “Computing with arrays of coupled oscillators: An application to preattentive texture discrimination,” *Neural Computation*, Vol.2, No.4, pp.458–471, 1990.
- [65] P. Suppes. *Representation and invariance of scientific structures*. CSLI Publications Stanford, CA, 2002.
- [66] E. Izhikevich and Y. Kuramoto, “Weakly coupled oscillators,” *Encyclopedia of Mathematical Physics*, Vol.5, p.448, 2006.

- [67] S. Ozawa, A. Roy, and D. Roussinov, “A multitask learning model for on-line pattern recognition,” *IEEE Transactions on Neural Networks*, Vol.20, No.3, pp.430–445, 2009.
- [68] A. Winfree, “Biological rhythms and the behavior of populations of coupled oscillators,” *Journal of Theoretical Biology*, Vol.16, No.1, pp.15–42, 1967.
- [69] Y. Kuramoto. *Chemical oscillations, waves, and turbulence*. Dover Publications, 2003.
- [70] H. Rowley, S. Baluja, and T. Kanade, “Neural network-based face detection,” *IEEE Transactions on Pattern Analysis and Machine Intelligence*, Vol.20, No.1, pp.23–38, 1998.
- [71] J. de Barros, G. Oas, and P. Suppes, “Response selection using neural phase oscillators,” *arXiv preprint arXiv:1208.6041*, 2012.
- [72] J. de Barros, “Joint probabilities and quantum cognition,” *arXiv preprint arXiv:1206.6706*, 2012.
- [73] J. de Barros, “Quantum-like model of behavioral response computation using neural oscillators,” *arXiv preprint arXiv:1207.0033*, 2012.

Abstract

In the recent years, the problem of modeling a cognitive task using phase oscillators has been receiving a significant attention. In this view, single neurons are no longer elementary computational units. Rather, coherent oscillating groups of neurons are seen as nodes of networks performing cognitive tasks. From this assumption, we develop a model of stimulus-response learning and recognition. The most significant part of our work is defining learning methods for natural frequencies and coupling weights in a coupled phase oscillator network under Kuramoto conditions.

In this thesis, we improved the previous models by not only emphasizing on the frequency of the oscillators but also taking into account the synaptic weights. We proposed a learning algorithm for the proposed model and applied it on a number of classification tasks including the Iris and Cars data sets. The results showed the superiority of the proposed model over the previous models in terms of classification rate. Also, the proposed model showed higher classification rate against noise as compared to previous models.

Keywords: Phase Oscillator, Network of Neural Oscillators, Kuramoto Model, Pattern Recognition



Sharif University of Technology
Computer Engineering Department

Master of Science Thesis

Artificial Intelligence

Learning Improvement in Phase Oscillator Models

By
Meysam Aghighi

Supervisor
Dr. Mahdi Jalili

Fall 2012